บทที่ 2
ทฤษฎี และงานวิจัยที่เกี่ยวข้อง

2.1 ทฤษฎีที่เกี่ยวข้องกับระบบงาน

โครงงานวิศวกรรมนี้มุ่งเน้นการพัฒนา"มือเทียมควบคุมด้วยสัญญาณกล้ามเนื้อ"เพื่อช่วยลดผลกระทบด้านคุณภาพชีวิตของผู้พิการทางร่างกายที่สูญเสียอวัยวะส่วนบน โดยเฉพาะผู้ที่สูญเสียมือในระดับใต้ข้อศอก (Below Elbow Amputation) ซึ่งเป็นกลุ่มที่ต้องการความช่วยเหลือด้านกายอุปกรณ์สูง วัตถุประสงค์ของโครงงานคือการออกแบบและสร้างต้นแบบมือเทียมที่สามารถลดต้นทุนการผลิตด้วยเทคโนโลยีการพิมพ์สามมิติและควบคุมการเคลื่อนไหวด้วยสัญญาณกล้ามเนื้อ(Electromyography : EMG) ร่วมกับการประมวลผลแบบเรียลไทม์ได้อย่างมีประสิทธิภาพ

2.1.1 ชีวกลศาสตร์และการทำงานของกล้ามเนื้อ (Biomechanics & Muscle Physiology)

2.1.1.1 กล้ามเนื้อมนุษย์ทำงานโดยอาศัยกระแสไฟฟ้าที่เกิดจากการหดตัวของเส้นใยกล้ามเนื้อเรียกว่าสัญญาณกล้ามเนื้อ ซึ่งมีแอมพลิจูดอยู่ในช่วงไมโครโวลต์ถึงมิลลิโวลต์ และมีช่วงความถี่หลักอยู่ที่ 20–500 Hz สัญญาณเหล่านี้สามารถตรวจจับได้จากผิวหนังโดยไม่ต้องผ่าตัด ทำให้เหมาะสำหรับการนำมาใช้ควบคุมอุปกรณ์กายอุปกรณ์แบบไม่รุกราน โครงงานนี้อ้างอิงแนวคิดดังกล่าวโดยใช้เซนเซอร์ เพื่อตรวจจับสัญญาณจากกล้ามเนื้อส่วนแขนที่เหลืออยู่ แล้วนำมาประมวลผลเพื่อสั่งให้มือเทียมเคลื่อนไหวตามเจตนาของผู้ใช้

2.1.2 การวัดและเซนเซอร์ (Sensing Theory)

2.1.2.1 ตลอดทศวรรษที่ผ่านมา เซนเซอร์วัดสัญญาณกล้ามเนื้อแบบพื้นผิวราคาประหยัดได้รับการพัฒนาอย่างต่อเนื่องเพื่อให้มีขนาดเล็กลง น้ำหนักเบา และสามารถส่งข้อมูลแบบไร้สายได้ อย่างไรก็ดี ความแม่นยำของเซนเซอร์ยังขึ้นอยู่กับสภาพแวดล้อม เช่น ความชื้น อุณหภูมิ และตำแหน่งการติดตั้ง ทำให้ต้องมีกระบวนการสอบเทียบ เพื่อให้ได้ข้อมูลที่ถูกต้องและเชื่อถือได้ โครงงานนี้จึงพัฒนาเครื่องมือสอบเทียบที่ช่วยให้ผู้ใช้สามารถบันทึกรูปแบบสัญญาณกล้ามเนื้อเฉพาะบุคคล เพื่อเพิ่มความแม่นยำในการสั่งการ

2.1.3 การประมวลผลสัญญาณ (Signal Processing Theory)

2.1.3.1 สัญญาณที่ได้จากเซนเซอร์มักมีสัญญาณรบกวน และค่าผิดปกติปะปนอยู่ ซึ่งอาจทำให้ระบบตัดสินใจผิดพลาดได้ วิธีการทางคณิตศาสตร์ที่นิยมใช้เพื่อลดสัญญาณรบกวน ได้แก่ ค่าเฉลี่ยเคลื่อนที่และค่าเฉลี่ยเคลื่อนที่แบบเอ็กซ์โปเนนเชียล ซึ่งช่วยปรับสัญญาณให้ราบเรียบมากขึ้น นอกจากนี้ยังมีเทคนิคการตรวจจับค่าผิดปกติโดยใช้พิสัยระหว่างควอไทล์ หรือค่ามัธยฐานของส่วนเบี่ยงเบนสัมบูรณ์ เพื่อตัดค่าที่อยู่นอกช่วงปกติออกไป การประมวลผลเหล่านี้ช่วยเพิ่มความเสถียรของระบบควบคุม และทำให้ผลการวิเคราะห์สอดคล้องกับแนวโน้มจริงมากกว่าการตอบสนองต่อค่าแบบเฉพาะหน้า ซึ่งสำคัญอย่างยิ่งต่อโครงงานที่ต้องตัดสินใจแบบอัตโนมัติ

2.1.4 ระบบควบคุมและอัตโนมัติ (Control System Theory)

2.1.4.1 ระบบควบคุมแบ่งออกเป็นสองกลุ่มหลักคือ ระบบควบคุมแบบวงเปิด และระบบควบคุมแบบวงปิด โครงงานนี้ใช้รูปแบบระบบควบคุมแบบวงปิด เนื่องจากการตัดสินใจขึ้นอยู่กับค่าที่วัดได้จากเซนเซอร์แบบต่อเนื่อง ระบบควบคุมพื้นฐานที่พบมากคือ การควบคุมแบบเปิด–ปิด ซึ่งเป็นการทำงานแบบสองสถานะ เช่น เปิดมอเตอร์เมื่อค่าสัญญาณสูงกว่าค่าที่กำหนด และหยุดเมื่อสัญญาณต่ำกว่าค่าที่กำหนด อย่างไรก็ตาม หากต้องการความละเอียดสูงขึ้น สามารถนำการควบคุมแบบสัดส่วน–อินทิกรัล–อนุพันธ์มาใช้ได้ ซึ่งช่วยควบคุมความเร็วรอบมอเตอร์หรือการปรับระดับแรงดันอากาศได้อย่างต่อเนื่อง นอกจากนี้ระบบควบคุมยังควรมีกลไกความปลอดภัย เช่น หากไม่มีสัญญาณภายใน 1 วินาที ระบบจะหยุดการทำงานอัตโนมัติเพื่อความปลอดภัย

2.1.5 ฮาร์ดแวร์และอิเล็กทรอนิกส์พื้นฐาน (Electronics Theory)

2.1.5.1 ฮาร์ดแวร์ในโครงงานใช้ Raspberry Pi 5 เป็นหน่วยประมวลผลกลางที่เชื่อมต่อกับเซนเซอร์และโมดูลไดรเวอร์ควบคุมมอเตอร์ TB6600 สำหรับควบคุมมอเตอร์สเต็ปเปอร์ที่ใช้ขับเคลื่อนการเคลื่อนไหวของนิ้วมือเทียม การทำงานของระบบอ้างอิงการส่งสัญญาณผ่านพอร์ตอินพุต–เอาต์พุตอเนกประสงค์ และโพรโทคอลสื่อสาร เช่น ไอทูซี และยูอาร์ที สำหรับการรับ–ส่งข้อมูลระหว่างชิ้นส่วน ระบบยังถูกออกแบบให้ปิดตัวอัตโนมัติเมื่อปิดโปรแกรม เพื่อยืดอายุการใช้งานของอุปกรณ์

2.1.6 สถาปัตยกรรมซอฟต์แวร์และการสื่อสารข้อมูล(Software & Communication Theory)

2.1.6.1 ระบบซอฟต์แวร์มักใช้แนวทางการเขียนโปรแกรมที่ขับเคลื่อนด้วยเหตุการณ์ เช่น การออกแบบโปรแกรมให้แยกชั้นการทำงาน ได้แก่ การอ่านเซนเซอร์ การตัดสินใจควบคุม การแสดงผล และการจัดเก็บข้อมูล เพื่อเพิ่มความยืดหยุ่นและลดข้อผิดพลาด โครงงานนี้ยังออกแบบการสื่อสารแบบอนุกรมให้ทนต่อความผิดพลาด เช่น การตรวจสอบส่วนหัวของข้อมูล การตรวจสอบเวลารอคอย และการป้องกันข้อมูลล้นบัฟเฟอร์

2.1.7 ข้อมูลและฐานข้อมูล (Data & Database Theory)

2.1.7.1 การจัดเก็บข้อมูลสัญญาณกล้ามเนื้อและโปรไฟล์ผู้ใช้ใช้ Firebase Realtime Database ซึ่งเป็นฐานข้อมูลบนระบบคลาวด์ที่รองรับการซิงโครไนซ์ข้อมูลแบบเรียลไทม์และสามารถเข้าถึงได้จากทุกที่ผ่านอินเทอร์เน็ต ข้อมูลโปรไฟล์การสอบเทียบของผู้ใช้แต่ละคนจะถูกบันทึกขึ้นระบบคลาวด์และเรียกใช้ในรอบต่อไปได้ทันที เพื่อลดเวลาในการตั้งค่าซ้ำ เพิ่มความแม่นยำในการควบคุมระยะยาว และเปิดโอกาสให้ผู้ดูแลระบบสามารถติดตามและอัปเดตข้อมูลจากระยะไกลได้

2.1.8 ความปลอดภัยและการจัดการสิทธิ์ (Security & IAM Theory)

2.1.8.1 ในระบบที่มีการบันทึกข้อมูลผู้ใช้ การออกแบบสิทธิ์การเข้าถึงและการเข้ารหัสข้อมูลเป็นสิ่งสำคัญ โดยเฉพาะข้อมูลส่วนบุคคลของผู้พิการที่เป็นข้อมูลอ่อนไหว ระบบควรอาศัยโพรโทคอลปรับเวลาเครือข่ายเพื่อซิงโครไนซ์เวลาให้ตรงกัน ซึ่งส่งผลโดยตรงต่อการประทับเวลาของข้อมูลการปรับเทียบ

2.1.9 การออกแบบประสบการณ์ผู้ใช้ (User Experience & HCI Theory)

2.1.9.1 การออกแบบเครื่องมือสอบเทียบต้องยึดหลักปฏิสัมพันธ์ระหว่างมนุษย์กับคอมพิวเตอร์ โดยเน้นให้ข้อมูลเข้าใจง่าย แสดงสถานะของสัญญาณกล้ามเนื้อแบบเรียลไทม์ผ่านกราฟ และมีปุ่มควบคุมที่มีการยืนยันก่อนสลับโหมด เพื่อความปลอดภัยและประสิทธิภาพในการใช้งาน

2.1.10 การทดสอบและรับรองคุณภาพ (Quality Assurance Theory)

2.1.10.1 การประเมินคุณภาพระบบต้องทำทั้งในสภาพแวดล้อมจริงและในห้องปฏิบัติการ โดยวัดประสิทธิภาพการจดจำสัญญาณกล้ามเนื้อได้ตามเกณฑ์หรือไม่ รวมถึงทดสอบกรณีพิเศษ เช่น เซนเซอร์ไม่ตอบสนอง การเชื่อมต่อขาดหาย หรือการสั่งงานถี่ ๆ เพื่อดูเสถียรภาพของระบบ นอกจากนี้ยังต้องวัดตัวชี้วัดด้านประสิทธิภาพ เช่น เวลาตอบสนอง ความถูกต้องแม่นยำ และความพร้อมใช้งานของระบบ เพื่อยืนยันความน่าเชื่อถือของระบบ

2.2 เทคโนโลยีและเครื่องมือที่ใช้พัฒนาระบบ (Technologies and Tools)

2.2.1 วิชวลสตูดิโอโค้ด (Visual Studio Code: VS Code)



รูปที่ 2.1 โลโก้โปรแกรมวิชวลสตูดิโอรหัส
ที่มา (https://code.visualstudio.com)

จากรูปที่ 2.1 โปรแกรม Visual Studio Code เป็นเครื่องมือสำหรับการพัฒนาโปรแกรม ดังแสดงในรูปที่ 2.1 จุดเด่นของโปรแกรมนี้เกิดจากแนวคิดและทฤษฎีทางวิศวกรรมซอฟต์แวร์และวิทยาการคอมพิวเตอร์ที่ถูกนำมาประยุกต์ใช้อย่างมีประสิทธิภาพ หลักการสำคัญประการแรกคือการออกแบบให้เป็นโปรแกรมแก้ไขซอร์สโค้ด ที่มีความคล่องตัว แต่ยังคงมีความสามารถเทียบเท่ากับสภาพแวดล้อมการพัฒนาแบบครบวงจรกล่าวคือ ผู้ใช้สามารถเปิดใช้งานได้อย่างรวดเร็วเช่นเดียวกับโปรแกรมแก้ไขข้อความทั่วไป ขณะเดียวกันก็มีเครื่องมือสนับสนุนการเขียนโปรแกรม เช่น การตรวจสอบรหัสคำสั่ง การเติมคำสั่งอัตโนมัติ และการจัดการไฟล์โครงการอย่างเป็นระบบ

Visual Studio Code ใช้สถาปัตยกรรมแบบแยกส่วนโดยแต่ละส่วนของโปรแกรมสามารถทำงานได้อย่างอิสระ และสามารถเพิ่มขยายความสามารถใหม่ ๆ ผ่านส่วนขยาย (Extension) ได้อย่างไม่จำกัด แนวคิดดังกล่าวสอดคล้องกับการออกแบบโปรแกรมเชิงวัตถุ (Object-Oriented Design) ที่มุ่งเน้นการห่อหุ้มข้อมูล (Encapsulation) การนำกลับมาใช้ซ้ำ และการแยกความรับผิดชอบ เพื่อให้ระบบมีความยืดหยุ่น ง่ายต่อการบำรุงรักษา และสามารถพัฒนาต่อยอดได้ในอนาคต

ในโครงงานนี้ใช้ Visual Studio Code ในการพัฒนาชุดคำสั่งภาษา Python สำหรับการประมวลผลสัญญาณกล้ามเนื้อ และพัฒนาเครื่องมือสอบเทียบเพื่อใช้ในการบันทึกและวิเคราะห์ข้อมูลสัญญาณกล้ามเนื้อสำหรับควบคุมการทำงานของมือเทียมอัจฉริยะ

2.2.2 Python



รูปที่ 2.2 ภาษาโปรแกรมคอมพิวเตอร์ระดับสูงไพทอน
ที่มา (https://www.python.org/)

ภาษาไพทอน (Python) เป็นภาษาโปรแกรม (Programming Language) ที่ได้รับความนิยมอย่างแพร่หลายทั่วโลก เนื่องจากได้รับการออกแบบให้เรียนรู้ได้ง่ายและสามารถประยุกต์ใช้ได้ในหลากหลายสาขา หัวใจสำคัญของภาษาไพทอนคือความสามารถในการอ่านและทำความเข้าใจรหัสต้นฉบับ (Source Code) ได้ง่าย โดยผู้พัฒนาภาษาได้ยึดแนวคิดที่ว่ารหัสคำสั่งควรมีลักษณะใกล้เคียงกับการอ่านภาษาอังกฤษ ทำให้ทั้งผู้เริ่มต้นและผู้เชี่ยวชาญสามารถทำความเข้าใจโครงสร้างโปรแกรมได้โดยไม่ซับซ้อน

ภาษาไพทอนรองรับการเขียนโปรแกรมเชิงวัตถุ (Object-Oriented Programming: OOP) โดยใช้คลาส (Class) และวัตถุ (Object) เป็นตัวแทนขององค์ประกอบต่าง ๆ ภายในระบบ นอกจากนี้ยังรองรับการเขียนโปรแกรมเชิงฟังก์ชัน และการเขียนโปรแกรมแบบคำสั่ง อีกด้วย ส่งผลให้สามารถเลือกใช้รูปแบบการพัฒนาโปรแกรมได้อย่างยืดหยุ่นตามลักษณะของงาน

ในโครงงานนี้ ภาษาไพทอนถูกใช้เป็นภาษาหลักในการพัฒนาระบบทั้งหมด ไม่ว่าจะเป็นการอ่านสัญญาณกล้ามเนื้อจากเซนเซอร์ การประมวลผลข้อมูลด้วยการเรียนรู้ของเครื่อง (Machine Learning) การควบคุมมอเตอร์ ผ่านพอร์ตอินพุต–เอาต์พุตอเนกประสงค์ และการพัฒนาเครื่องมือสอบเทียบ

สาเหตุที่เลือกใช้ภาษาไพทอนในโครงงานนี้ เนื่องจากมีคลังโปรแกรม (Library) จำนวนมากที่รองรับงานด้านการประมวลผลสัญญาณและปัญญาประดิษฐ์ เช่น NumPy, SciPy และ scikit-learn ซึ่งช่วยลดเวลาในการพัฒนาและเพิ่มประสิทธิภาพของระบบ นอกจากนี้ยังสามารถทำงานร่วมกับ Raspberry Pi 5 ได้โดยตรง ทำให้ลดความซับซ้อนในการพัฒนาระบบฮาร์ดแวร์และซอฟต์แวร์ให้ทำงานร่วมกันได้อย่างมีประสิทธิภาพ

2.2.3 Tkinter



รูปที่ 2.3 เครื่องมือสร้างส่วนติดต่อผู้ใช้แบบกราฟิกทินเคอร์

ทินเตอร์ (Tkinter) เป็นส่วนประกอบมาตรฐานที่มาพร้อมกับภาษาไพทอน ใช้สำหรับสร้างส่วนติดต่อผู้ใช้แบบกราฟิก (Graphical User Interface: GUI) เพื่อให้ผู้ใช้สามารถโต้ตอบกับโปรแกรมผ่านหน้าต่าง ปุ่มกด กล่องข้อความ และองค์ประกอบกราฟิกอื่น ๆ ได้อย่างสะดวก การพัฒนาทินเตอร์มีพื้นฐานมาจากแนวคิดทางวิศวกรรมซอฟต์แวร์และการออกแบบปฏิสัมพันธ์ระหว่างมนุษย์กับคอมพิวเตอร์ ซึ่งมุ่งเน้นให้โปรแกรมสามารถสื่อสารกับผู้ใช้ได้อย่างเป็นมิตร เข้าใจง่าย และลดความซับซ้อนของการใช้งานเมื่อเทียบกับการสั่งงานผ่านบรรทัดคำสั่ง

ทินเตอร์ทำงานตามแนวคิดการเขียนโปรแกรมที่ขับเคลื่อนด้วยเหตุการณ์ โดยโปรแกรมจะรอการกระทำจากผู้ใช้ เช่น การคลิกปุ่ม การกรอกข้อมูล หรือการเลือกคำสั่ง จากนั้นจึงดำเนินการตามเหตุการณ์ที่เกิดขึ้น แนวคิดดังกล่าวช่วยให้สามารถพัฒนาโปรแกรมที่มีการตอบสนองต่อผู้ใช้ได้อย่างมีประสิทธิภาพ และเหมาะสำหรับการสร้างโปรแกรมที่ต้องมีการโต้ตอบกับผู้ใช้งานอยู่ตลอดเวลา

ในโครงงานนี้ใช้ Tkinter ในการพัฒนาเครื่องมือสอบเทียบ (Calibration Tool) ซึ่งเป็นเครื่องมือสำหรับบันทึกรูปแบบสัญญาณกล้ามเนื้อเฉพาะบุคคล แสดงผลสัญญาณกล้ามเนื้อแบบเรียลไทม์ผ่านกราฟ และเลือกแบบจำลองการเรียนรู้ของเครื่องที่ต้องการใช้งาน การออกแบบส่วนติดต่อผู้ใช้เน้นความเรียบง่าย ชัดเจน และใช้งานได้สะดวก เพื่อให้ผู้ใช้งานสามารถเรียนรู้และใช้งานระบบได้อย่างรวดเร็ว แม้ไม่มีความรู้ด้านเทคโนโลยีหรือการเขียนโปรแกรมมาก่อน

2.2.4 Scikit-learn (Machine Learning Library)



รูปที่ 2.4 คลังโปรแกรม Machine Learning สำหรับภาษาไพทอน

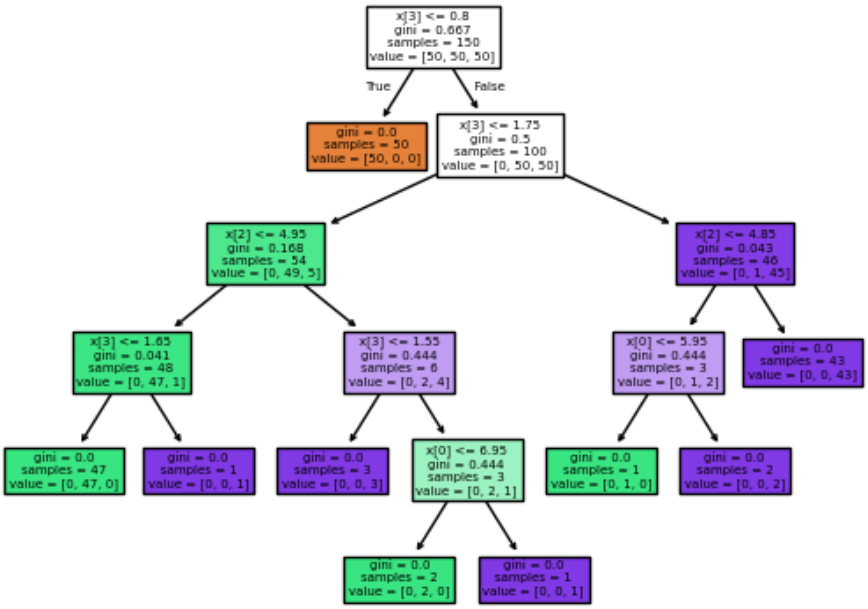
ที่มา (https://scikit-learn.org/)

ซายคิทเลิร์น (scikit-learn) เป็นคลังโปรแกรมสำหรับการเรียนรู้ของเครื่อง (Machine Learning Library) ที่ได้รับความนิยมอย่างแพร่หลายในภาษาไพทอน (Python) โดยรวบรวมอัลกอริธึมการเรียนรู้ของเครื่องหลากหลายประเภทไว้ในชุดเดียว ซึ่งสามารถนำมาใช้ในการวิเคราะห์และจำแนกสัญญาณกล้ามเนื้อ เพื่อทำนายเจตนาของผู้ใช้งานว่าต้องการกำมือหรือคลายมือได้อย่างมีประสิทธิภาพ

ซายคิทเลิร์นได้รับการออกแบบให้ใช้งานง่าย มีโครงสร้างการทำงานที่เป็นมาตรฐาน และสามารถทำงานร่วมกับคลังโปรแกรมด้านวิทยาการข้อมูลอื่น ๆ ได้เป็นอย่างดี จึงเหมาะสำหรับการพัฒนาระบบวิเคราะห์ข้อมูลและระบบปัญญาประดิษฐ์ นอกจากนี้ยังมีเครื่องมือสำหรับการเตรียมข้อมูล การฝึกโมเดล การประเมินผล และการปรับแต่งประสิทธิภาพของโมเดลอย่างครบถ้วน

ในโครงงานนี้ใช้ซายคิทเลิร์นในการฝึกโมเดล (Train Model) จากข้อมูลการสอบเทียบของผู้ใช้แต่ละคน โดยระบบจะนำข้อมูลสัญญาณกล้ามเนื้อมาวิเคราะห์และสร้างโมเดลสำหรับจำแนกรูปแบบการเคลื่อนไหว จากนั้นจึงเปรียบเทียบประสิทธิภาพของอัลกอริธึมแต่ละประเภท และเลือกโมเดลที่ให้ค่าความถูกต้องสูงที่สุดมาใช้ในการควบคุมมือเทียมแบบเรียลไทม์ เพื่อเพิ่มความแม่นยำและความน่าเชื่อถือของระบบในการใช้งานจริง

2.2.5 ต้นไม้ตัดสินใจ (Decision Tree)



รูปที่ 2.4.1 โครงสร้างโมเดลต้นไม้ตัดสินใจ
ที่มา (https://scikit-learn.org/stable/modules/tree.html)

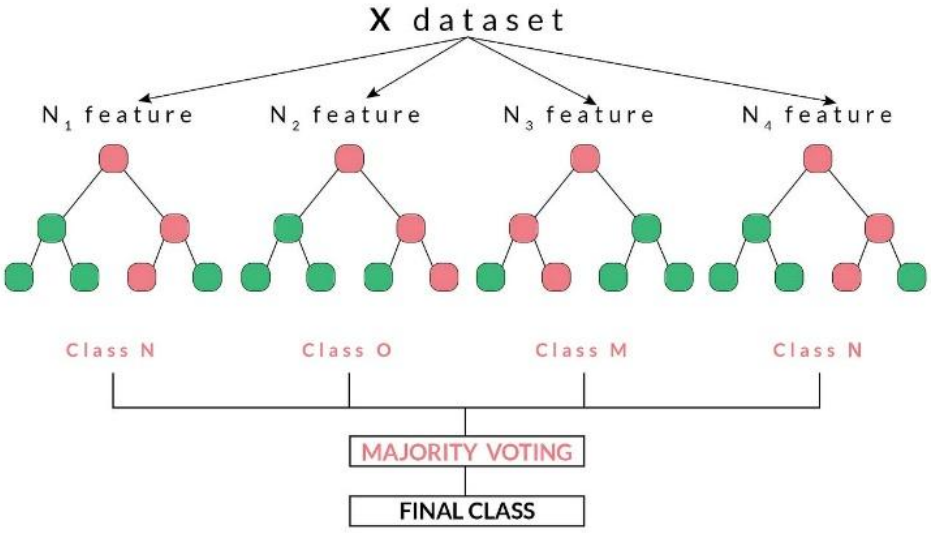
ต้นไม้ตัดสินใจเป็นอัลกอริธึมการเรียนรู้ของเครื่องแบบมีผู้สอน (Supervised Learning) ที่จำลองกระบวนการตัดสินใจในรูปแบบโครงสร้างต้นไม้ โดยแบ่งข้อมูลออกเป็นกลุ่มย่อยตามเงื่อนไขของคุณลักษณะ (Feature) ต่าง ๆ ภายในข้อมูล แต่ละจุดตัดสินใจจะเรียกว่าโหนด (Node) และจะมีการแตก

แขนงไปยังโหนดย่อยจนกระทั่งถึงใบ (Leaf) ซึ่งเป็นผลลัพธ์สุดท้ายของการจำแนกประเภทหรือการพยากรณ์ข้อมูล

หลักการทำงานของต้นไม้ตัดสินใจอาศัยแนวคิดของค่าการเพิ่มขึ้นของสารสนเทศ (Information Gain) หรือค่าความไม่บริสุทธิ์ของจินี (Gini Impurity) ในการเลือกเงื่อนไขที่เหมาะสมที่สุดสำหรับการแบ่งข้อมูลในแต่ละขั้นตอน โดยมีเป้าหมายเพื่อให้ข้อมูลภายในแต่ละกลุ่มมีความบริสุทธิ์ (Purity) หรือมีลักษณะใกล้เคียงกันมากที่สุด ส่งผลให้โมเดลสามารถตัดสินใจได้อย่างมีประสิทธิภาพ อีกทั้งยังเป็นโมเดลที่สามารถอธิบายผลการตัดสินใจได้ง่าย เนื่องจากสามารถติดตามเส้นทางการตัดสินใจจากรากของต้นไม้ไปยังผลลัพธ์ได้อย่างชัดเจน

ในโครงงานนี้ใช้ต้นไม้ตัดสินใจเป็นหนึ่งในโมเดลพื้นฐานสำหรับการเปรียบเทียบประสิทธิภาพในการจำแนกสัญญาณกล้ามเนื้อของผู้ใช้งาน โดยโมเดลจะเรียนรู้รูปแบบของสัญญาณจากข้อมูลการสอบเทียบและนำมาใช้ในการทำนายการเคลื่อนไหวที่ต้องการ ข้อดีที่สำคัญของต้นไม้ตัดสินใจคือมีความรวดเร็วในการทำนายผล สามารถทำงานได้แบบเรียลไทม์ และมีความสามารถในการอธิบายเหตุผลของการตัดสินใจได้อย่างชัดเจน ซึ่งช่วยให้สามารถตรวจสอบ ปรับปรุง และพัฒนาระบบควบคุมมือเทียมได้อย่างมีประสิทธิภาพ

2.2.6 ป่าสุ่ม (Random Forest)



รูปที่ 2.4.2 โครงสร้างโมเดล Random Forest

ที่มา (https://lengyi.medium.com/random-forest-regression-double-declining-balance-residual-value-model-6af8fd0c8709)

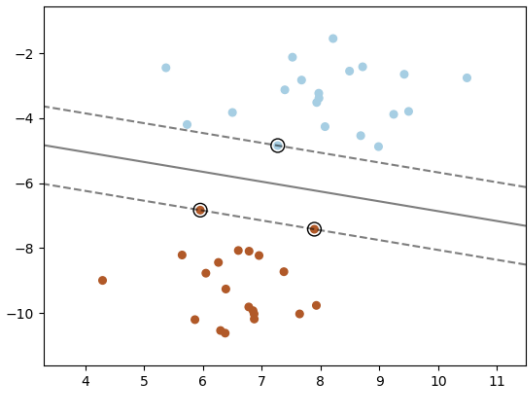
ป่าสุ่มเป็นอัลกอริธึมการเรียนรู้ของเครื่องแบบรวมผลหลายโมเดล (Ensemble Learning) ที่พัฒนาขึ้นจากแนวคิดของต้นไม้ตัดสินใจ โดยสร้างต้นไม้ตัดสินใจจำนวนมากรวมกันเป็นกลุ่มหรือป่า แต่ละต้นจะถูกฝึกด้วยข้อมูลชุดย่อยที่ได้จากการสุ่มตัวอย่างแบบบูตสแตรป (Bootstrap Sampling) จากชุด

ข้อมูลเดิม และมีการสุ่มเลือกคุณลักษณะบางส่วนเพื่อใช้ในการแบ่งข้อมูลในแต่ละโหนด ส่งผลให้ต้นไม้แต่ละต้นมีความแตกต่างกันและสามารถเรียนรู้ข้อมูลได้หลากหลายมุมมอง

ผลลัพธ์สุดท้ายของป่าสุ่มจะได้จากการลงคะแนนเสียงข้างมาก (Majority Voting) ของต้นไม้ทั้งหมดในกรณีการจำแนกประเภท หรือการหาค่าเฉลี่ยของผลลัพธ์จากต้นไม้ทั้งหมดในกรณีการพยากรณ์ค่า วิธีการดังกล่าวช่วยลดปัญหาการเรียนรู้ข้อมูลเฉพาะชุดมากเกินไป (Overfitting) ที่มักเกิดขึ้นกับต้นไม้ตัดสินใจเพียงต้นเดียว ส่งผลให้โมเดลมีความสามารถในการทำนายข้อมูลใหม่ได้ดียิ่งขึ้น นอกจากนี้ยังสามารถวิเคราะห์ความสำคัญของเพื่อระบุว่าข้อมูลใดมีอิทธิพลต่อการตัดสินใจของโมเดลมากที่สุด

ในโครงงานนี้ใช้ป่าสุ่มเป็นโมเดลหลักสำหรับการจำแนกสัญญาณกล้ามเนื้อ เนื่องจากมีความสามารถในการจัดการกับข้อมูลที่มีความซับซ้อนสูง ทนทานต่อสัญญาณรบกวนและค่าผิดปกติที่มักพบในสัญญาณกล้ามเนื้อ อีกทั้งยังสามารถรองรับข้อมูลที่มีคุณลักษณะจำนวนมากได้อย่างมีประสิทธิภาพ ส่งผลให้มีความเหมาะสมต่อการวิเคราะห์สัญญาณกล้ามเนื้อของผู้ใช้งานแต่ละบุคคล ซึ่งมีรูปแบบสัญญาณที่แตกต่างกัน และช่วยเพิ่มความแม่นยำในการควบคุมการทำงานของมือเทียมแบบเรียลไทม์

2.2.7 เครื่องเวกเตอร์สนับสนุน (Support Vector Machine: SVM)



รูปที่ 2.4.3 หลักการทำงานของ Support Vector Machine
ที่มา (https://scikit-learn.org/stable/modules/svm.html)

เครื่องเวกเตอร์สนับสนุนเป็นอัลกอริธึมการเรียนรู้ของเครื่องที่ใช้สำหรับการจำแนกประเภทและการพยากรณ์ข้อมูล โดยมีหลักการสำคัญคือการหาระนาบแบ่งประเภท (Hyperplane) ที่สามารถแยกข้อมูลแต่ละกลุ่มออกจากกันได้อย่างมีประสิทธิภาพที่สุด ระนาบดังกล่าวจะถูกเลือกให้มีระยะห่างจากข้อมูลของแต่ละกลุ่มมากที่สุด หรือที่เรียกว่า ระยะขอบสูงสุด (Maximum Margin) ซึ่งช่วยเพิ่มความสามารถในการจำแนกข้อมูลใหม่ได้อย่างถูกต้อง

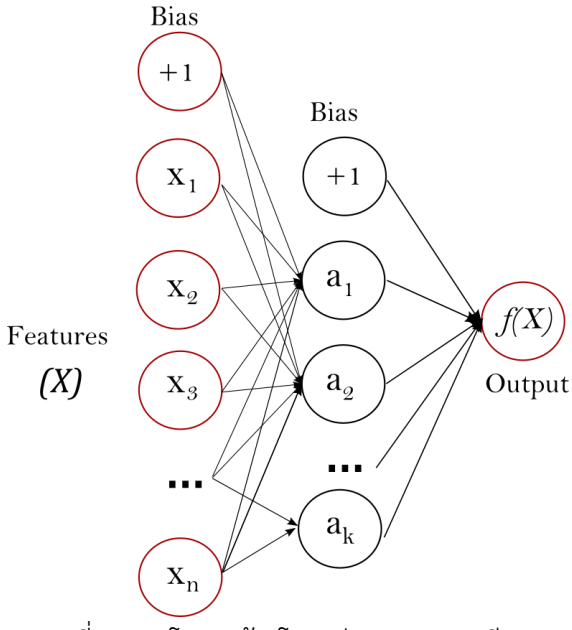
การกำหนดระนาบแบ่งประเภทจะอาศัยจุดข้อมูลที่อยู่ใกล้ขอบเขตการแบ่งมากที่สุด ซึ่งเรียกว่า เวกเตอร์สนับสนุน (Support Vectors) โดยจุดข้อมูลเหล่านี้มีบทบาทสำคัญต่อการตัดสินใจของโมเดล ในกรณีที่ข้อมูลไม่สามารถแบ่งแยกได้ด้วยเส้นตรง เครื่องเวกเตอร์สนับสนุนสามารถใช้เทคนิคเคอร์เนล (Kernel Trick) เพื่อแปลงข้อมูลไปยังมิติที่สูงขึ้น ทำให้สามารถสร้างขอบเขตการแบ่งที่ซับซ้อนมาก

ขึ้นได้ ตัวอย่างเคอร์เนลที่นิยมใช้งาน ได้แก่ เคอร์เนลฐานรัศมี (RBF Kernel) และเคอร์เนลพหุนาม (Polynomial Kernel)

เครื่องเวกเตอร์สนับสนุนมีจุดเด่นด้านความสามารถในการจัดการข้อมูลที่มีมิติสูง และสามารถให้ผลลัพธ์ที่ดีแม้มีจำนวนข้อมูลไม่มากนัก นอกจากนี้ยังมีความสามารถในการลดผลกระทบจากค่าผิดปกติ (Outlier) ได้ในหลายกรณี จึงได้รับความนิยมในการแก้ปัญหาการจำแนกประเภทข้อมูลในงานด้านการเรียนรู้ของเครื่อง

ในโครงงานนี้ใช้เครื่องเวกเตอร์สนับสนุนเป็นหนึ่งในโมเดลที่นำมาทดสอบสำหรับการจำแนกสัญญาณกล้ามเนื้อ เนื่องจากมีประสิทธิภาพสูงกับชุดข้อมูลขนาดเล็กถึงขนาดกลาง ซึ่งสอดคล้องกับข้อมูลการสอบเทียบที่เก็บจากผู้ใช้แต่ละคน อีกทั้งยังสามารถจำแนกรูปแบบสัญญาณที่มีความซับซ้อนได้อย่างมีประสิทธิภาพ จึงเป็นอีกทางเลือกหนึ่งที่เหมาะสมสำหรับการนำมาใช้ควบคุมการทำงานของมือเทียมแบบเรียลไทม์

2.2.8 โครงข่ายประสาทเทียม (Neural Network)



รูปที่ 2.4.4 โครงสร้างโครงข่ายประสาทเทียม

ที่มา (https://scikit-learn.org/stable/modules/neural_networks_supervised.html)

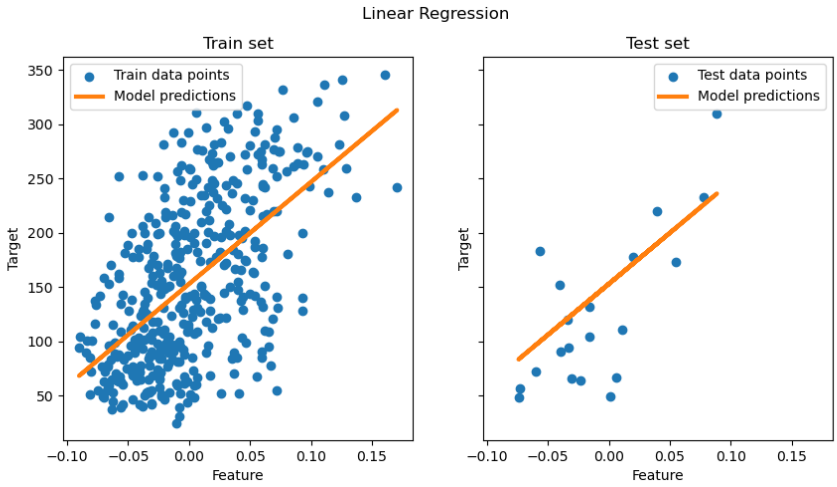
โครงข่ายประสาทเทียม เป็นอัลกอริธึมการเรียนรู้ของเครื่องที่ได้รับแรงบันดาลใจจากการทำงานของระบบประสาทในสมองมนุษย์ โดยประกอบด้วยชั้นอินพุต (Input Layer) ชั้นซ่อน (Hidden Layer) และชั้นเอาต์พุต (Output Layer) ซึ่งแต่ละชั้นประกอบด้วยโหนดจำนวนมากที่เชื่อมต่อถึงกันผ่านค่าน้ำหนัก (Weight) การส่งผ่านข้อมูลระหว่างโหนดจะถูกควบคุมด้วยฟังก์ชันกระตุ้น (Activation Function) เพื่อกำหนดว่าข้อมูลจะถูกส่งต่อไปยังชั้นถัดไปหรือไม่ ตัวอย่างฟังก์ชันกระตุ้นที่นิยมใช้ ได้แก่ เรลู (ReLU) และซิกมอยด์ (Sigmoid)

กระบวนการฝึกโครงข่ายประสาทเทียมอาศัยขั้นตอนการแพร่ย้อนกลับ (Backpropagation) ร่วมกับวิธีการลดค่าความคลาดเคลื่อนแบบไล่ระดับ (Gradient Descent) เพื่อปรับค่าน้ำหนักของการเชื่อมต่อระหว่างโหนดให้เหมาะสมที่สุด ทำให้โมเดลสามารถเรียนรู้รูปแบบและความสัมพันธ์ที่ซับซ้อนภายในข้อมูลได้อย่างมีประสิทธิภาพ โดยเฉพาะข้อมูลที่ไม่สามารถอธิบายได้ด้วยความสัมพันธ์เชิงเส้น

โครงข่ายประสาทเทียมมีจุดเด่นในการเรียนรู้ข้อมูลที่มีรูปแบบซับซ้อนและมีจำนวนตัวแปรจำนวนมาก จึงถูกนำไปประยุกต์ใช้ในงานด้านการรู้จำรูปภาพ การประมวลผลภาษา การพยากรณ์ข้อมูล และงานด้านปัญญาประดิษฐ์อีกหลากหลายประเภท

ในโครงงานนี้ใช้โครงข่ายประสาทเทียมแบบมัลติเลเยอร์เพอร์เซปตรอน (Multilayer Perceptron: MLP) จากไลบรารี scikit-learn สำหรับการจำแนกสัญญาณกล้ามเนื้อ เนื่องจากสามารถเรียนรู้ความสัมพันธ์แบบไม่เป็นเชิงเส้น (Non-linear Relationship) ระหว่างคุณลักษณะต่าง ๆ ของข้อมูลได้เป็นอย่างดี ซึ่งสอดคล้องกับลักษณะของสัญญาณกล้ามเนื้อที่มีความซับซ้อนและแตกต่างกันในแต่ละบุคคล ส่งผลให้สามารถเพิ่มประสิทธิภาพในการจำแนกสัญญาณและช่วยให้การควบคุมมือเทียมมีความแม่นยำมากยิ่งขึ้น

2.2.9 แบบจำลองเชิงเส้น (Linear Model)



รูปที่ 2.4.5 หลักการทำงานของโมเดลเชิงเส้น (Logistic Regression)
ที่มา (https://scikit-learn.org/stable/modules/linear_model.html)

โมเดลเชิงเส้นเป็นกลุ่มอัลกอริธึมการเรียนรู้ของเครื่องที่สร้างความสัมพันธ์ระหว่างคุณลักษณะของข้อมูลและผลลัพธ์ในรูปแบบสมการเชิงเส้น โดยมีหลักการสำคัญคือการกำหนดค่าน้ำหนักให้กับคุณลักษณะแต่ละตัวเพื่อใช้ในการคำนวณผลลัพธ์ สำหรับงานจำแนกประเภทนิยมใช้การถดถอยลอจิสติก (Logistic Regression) ซึ่งเป็นอัลกอริธึมที่ใช้ฟังก์ชันซิกมอยด์ (Sigmoid Function) ในการแปลงค่าผลรวมเชิงเส้นให้เป็นค่าความน่าจะเป็น ของแต่ละกลุ่มข้อมูล เพื่อใช้ประกอบการตัดสินใจในการจำแนกประเภท

จุดเด่นของโมเดลเชิงเส้นคือมีความโปร่งใส และสามารถอธิบายผลการตัดสินใจได้ง่าย เนื่องจากค่าน้ำหนักของแต่ละคุณลักษณะสามารถตีความได้โดยตรงว่ามีผลต่อผลลัพธ์มากน้อยเพียงใด นอกจากนี้ยังใช้ทรัพยากรในการประมวลผลน้อย มีความรวดเร็วในการฝึกและการทำนายผล จึงมักถูกนำมาใช้เป็นโมเดลสำหรับเปรียบเทียบประสิทธิภาพกับโมเดลที่มีความซับซ้อนสูงกว่า

ในโครงงานนี้ใช้โมเดลเชิงเส้นเป็นโมเดลพื้นฐานสำหรับเปรียบเทียบประสิทธิภาพกับอัลกอริธึมอื่น เช่น ป่าสุ่ม และโครงข่ายประสาทเทียม โดยหากข้อมูลสัญญาณกล้ามเนื้อของผู้ใช้งานมีลักษณะที่สามารถแบ่งแยกได้ด้วยความสัมพันธ์เชิงเส้น โมเดลเชิงเส้นอาจให้ผลลัพธ์ที่มีความแม่นยำเพียงพอต่อการใช้งานจริง ขณะเดียวกันยังใช้ทรัพยากรในการประมวลผลต่ำกว่ามาก ทำให้เหมาะสำหรับการประมวลผลแบบตลอดเวลา บน Raspberry Pi 5 ซึ่งมีข้อจำกัดด้านทรัพยากรเมื่อเทียบกับคอมพิวเตอร์ประสิทธิภาพสูง

2.2.10 การจำแนกแบบนาอีฟเบย์ (Naive Bayes)

$$P(x_i \mid y) = \frac{1}{\sqrt{2\pi\sigma_y^2}} \exp\left(-\frac{(x_i - \mu_y)^2}{2\sigma_y^2}\right)$$

รูปที่ 2.4.6 หลักการทำงานของนาอีฟเบย์
ที่มา (https://scikit-learn.org/stable/modules/naive_bayes.html)

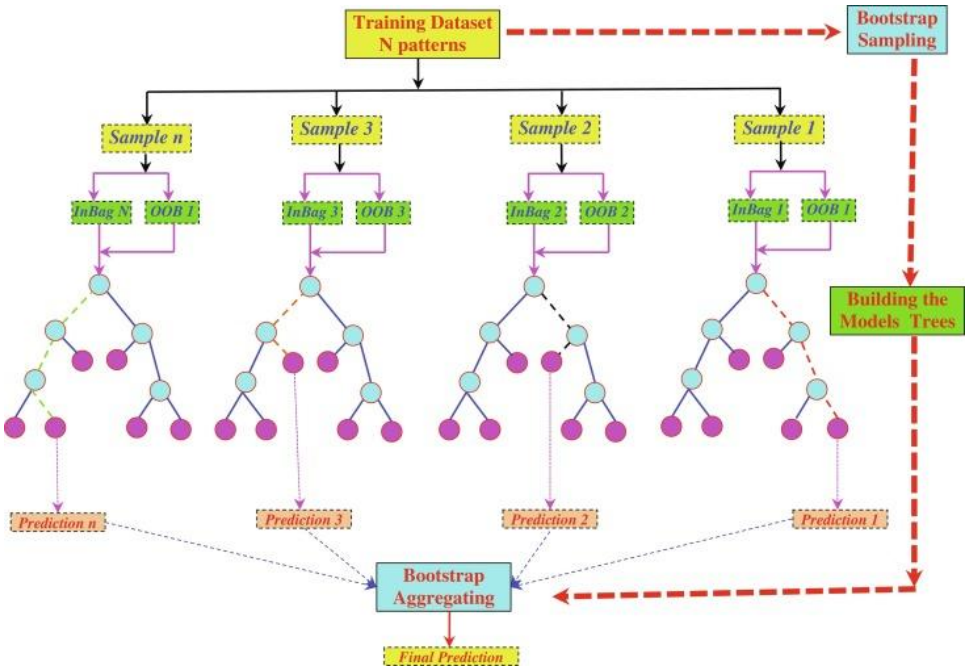
การจำแนกแบบเบย์อย่างไร้เดียงสา เป็นอัลกอริธึมการเรียนรู้ของเครื่องที่สร้างขึ้นจากทฤษฎีบทของเบย์ (Bayes' Theorem) ซึ่งคำนวณความน่าจะเป็นภายหลัง (Posterior Probability) ของแต่ละประเภทข้อมูล โดยอาศัยข้อสมมติฐานสำคัญที่ว่า คุณลักษณะ (Feature) แต่ละตัวมีความเป็นอิสระต่อกันโดยมีเงื่อนไขจากประเภทข้อมูล (Conditional Independence) แม้ข้อสมมติฐานนี้มักไม่เป็นจริงทั้งหมดในข้อมูลจริง แต่ในทางปฏิบัติอัลกอริธึมนี้ยังคงให้ผลลัพธ์ที่ดีในหลายกรณี จึงเป็นที่มาของคำว่า "ไร้เดียงสา" (Naive)

รูปแบบที่ใช้ในโครงงานนี้คือ Gaussian Naive Bayes ซึ่งสมมติว่าคุณลักษณะเชิงตัวเลขแต่ละตัวมีการกระจายตัวแบบปกติ (Gaussian Distribution) ภายในแต่ละประเภทข้อมูล จุดเด่นของ Naive Bayes คือมีความเร็วในการเทรนและทำนายสูงมาก ใช้ทรัพยากรในการประมวลผลต่ำ และทำงานได้ดีแม้มีข้อมูลฝึกไม่มาก จึงมักถูกใช้เป็นโมเดลพื้นฐานสำหรับเปรียบเทียบ ประสิทธิภาพกับโมเดลที่มีความซับซ้อนสูงกว่า

ในโครงงานนี้ใช้ Naive Bayes จากไลบรารี scikit-learn (GaussianNB) เป็นหนึ่งในโมเดลพื้นฐานสำหรับจำแนกสัญญาณกล้ามเนื้อ เช่นเดียวกับ SVM โมเดลนี้รองรับการเทรนแบบ partial_fit ซึ่งเป็นการเทรนแบบออนไลน์จริง (อัพเดตแบบจำลองทีละส่วนจากข้อมูลใหม่ โดยไม่ต้องเทรนซ้ำจากศูนย์

ทั้งหมด) ต่างจากโมเดลอื่นส่วนใหญ่ในโครงงานที่ใช้วิธี Full-refit (เทรนใหม่ทั้งหมดทุกครั้งที่ถึงรอบ) ทำให้ Naive Bayes เหมาะสำหรับการทดสอบรูปแบบการเทรนแบบต่อเนื่องควบคู่กับ SVM

2.2.11 ต้นไม้แบบสุ่ม (Random Tree / Extra Tree)

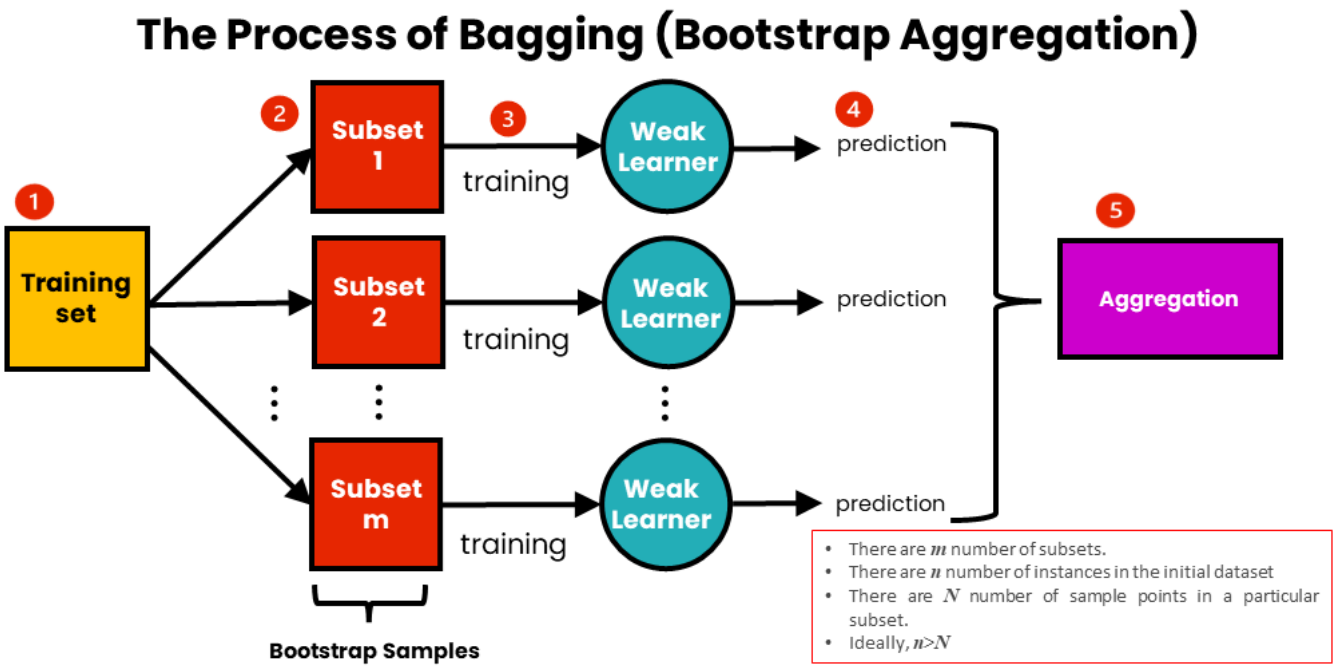


รูปที่ 2.4.7 หลักการทำงานของต้นไม้แบบสุ่ม
ที่มา (https://www.sciencedirect.com/science/chapter/edited-volume/abs/pii/B9780128219614000063)

ต้นไม้แบบสุ่ม เป็นรูปแบบหนึ่งของอัลกอริธึมต้นไม้ตัดสินใจที่เพิ่มระดับการสุ่มเข้าไปในกระบวนการสร้างต้นไม้มากกว่าต้นไม้ตัดสินใจ แบบมาตรฐาน (เช่น C4.5 ในหัวข้อ 2.2.5) โดยแทนที่จะเลือกจุดแบ่งข้อมูล (Split Point) ที่ดีที่สุดในแต่ละคุณลักษณะเสมอ ต้นไม้แบบสุ่มจะสุ่มเลือกเกณฑ์การแบ่งข้อมูลขึ้นมาจำนวนหนึ่งแล้วเลือกเกณฑ์ที่ดีที่สุดจากกลุ่มที่สุ่มได้นั้นแทน วิธีการดังกล่าวช่วยลดความแปรปรวน (Variance) ของแบบจำลองและลดโอกาสเกิดการเรียนรู้ข้อมูลเฉพาะชุดมากเกินไป (Overfitting) เมื่อเทียบกับต้นไม้ตัดสินใจแบบมาตรฐานที่ใช้ต้นไม้เพียงต้นเดียว

ในโครงงานนี้ใช้ Extra Tree จากไลบรารี scikit-learn (ExtraTreeClassifier) กำหนดความลึกสูงสุดของต้นไม้ (max_depth) เท่ากับ 5 เช่นเดียวกับ Decision Tree และ Random Forest เพื่อให้เปรียบเทียบกันได้อย่างยุติธรรมภายใต้เงื่อนไขเดียวกัน เป็นหนึ่งในโมเดลพื้นฐานสำหรับเปรียบเทียบประสิทธิภาพการจำแนกสัญญาณกล้ามเนื้อ โดยมีความรวดเร็วในการเทรนใกล้เคียงกับ ต้นไม้ตัดสินใจแบบมาตรฐาน แต่มีแนวโน้มทนทานต่อความแปรปรวนของสัญญาณรบกวนในข้อมูลได้ดีกว่าเล็กน้อยจากการสุ่มเกณฑ์การแบ่งข้อมูล

2.2.12 การรวมกลุ่มแบบแบ็กกิง (Bagging)



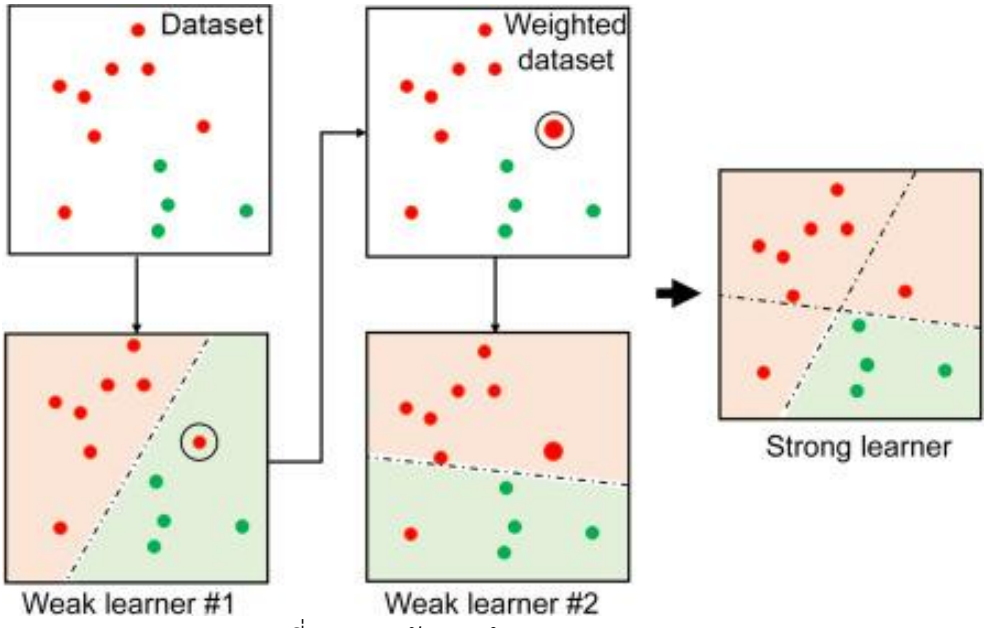
รูปที่ 2.4.8 หลักการทำงานของแบ็กกิง

ที่มา (https://medium.com/@brijesh_soni/boost-your-machine-learning-models-with-bagging-a-powerful-ensemble-learning-technique-692bfc4d1a51)

การรวมกลุ่มแบบแบ็กกิง หรือ Bootstrap Aggregating เป็นเทคนิคการรวมผลหลายแบบจำลอง (Ensemble Learning) ที่ทำงานร่วมกับแบบจำลองพื้นฐาน (Base Model) ชนิดใดก็ได้ โดยหลักการสำคัญคือการสุ่มตัวอย่างข้อมูลฝึกแบบสุ่มคืนกลับ (Bootstrap Sampling) ขึ้นมาหลายชุดจากชุดข้อมูลเดิม แล้วนำแต่ละชุดไปฝึกแบบจำลองพื้นฐานแยกจากกันเป็นจำนวนหลายตัว จากนั้นจึงรวมผลการทำนายของแบบจำลองทั้งหมดด้วยการลงคะแนนเสียงข้างมากในกรณีการจำแนกประเภท เทคนิคนี้ช่วยลดความแปรปรวน ของแบบจำลองและเพิ่มความเสถียรของผลการทำนาย โดยเฉพาะกับแบบจำลองที่มีแนวโน้ม Overfitting ง่าย เช่น ต้นไม้ตัดสินใจ

ในโครงงานนี้ใช้ BaggingClassifier จากไลบรารี scikit-learn ห่อหุ้ม (Wrap) แบบจำลองพื้นฐานที่ผู้ดูแลระบบเลือกไว้ โดยปรับจำนวนแบบจำลองย่อย (n_estimators) ตามความหนักเบาของแบบจำลองพื้นฐาน กล่าวคือหากเป็นแบบจำลองที่ใช้ทรัพยากร ในการประมวลผลสูงอยู่แล้ว เช่น โครงข่ายประสาทเทียม เครื่องเวกเตอร์สนับสนุน ป่าสุ่ม XGBoost หรือ CatBoost ระบบจะลดจำนวนแบบจำลองย่อยเหลือ 6 ตัว แต่หากเป็นแบบจำลองที่เบากว่า ระบบจะใช้ 10 ตัว เพื่อควบคุมเวลาในการเทรนให้เหมาะสมกับทรัพยากร ที่จำกัดของ Raspberry Pi 5 โดยไม่ให้หน้าจอค้างระหว่างการเทรน

2.2.13 แบบอะดาบูสต์ (AdaBoost: Adaptive Boosting)



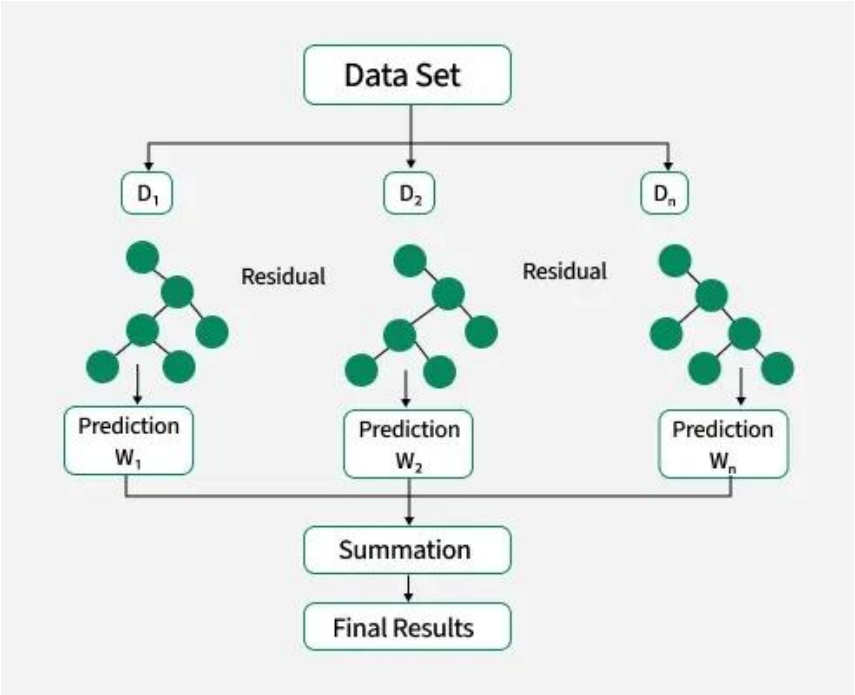
รูปที่ 2.4.9 หลักการทำงานของ AdaBoost

ที่มา (https://scikit-learn.org/stable/modules/ensemble.html#adaboost)]

การรวมกลุ่มแบบปรับเพิ่มน้ำหนัก หรือ Adaptive Boosting เป็นเทคนิคการรวมผลหลายแบบจำลองอีกรูปแบบหนึ่งที่แตกต่างจาก Bagging ตรงที่แบบจำลองย่อยแต่ละตัวจะถูกฝึกตามลำดับ (Sequential) ไม่ใช่แบบขนาน โดยในแต่ละรอบ ระบบจะเพิ่มน้ำหนัก ให้กับตัวอย่างข้อมูลที่แบบจำลองรอบก่อนหน้าทำนายผิดพลาด เพื่อให้แบบจำลองรอบถัดไปมุ่งเน้นเรียนรู้ตัวอย่างที่ยากขึ้น เป็นพิเศษ ผลการทำนายสุดท้ายได้จากการรวมผลของแบบจำลองย่อยทั้งหมดแบบถ่วงน้ำหนักตามความแม่นยำของแต่ละตัว เทคนิคนี้ ช่วยลดความคลาดเคลื่อนเชิงระบบ (Bias) ของแบบจำลอง และมักให้ความแม่นยำสูงขึ้นเมื่อเทียบกับแบบจำลองเดี่ยว

ในโครงงานนี้ใช้ AdaBoostClassifier จากไลบรารี scikit-learn ปรับจำนวนแบบจำลองย่อยตามความหนักเบาของแบบจำลองพื้นฐาน เช่นเดียวกับ Bagging (6 ตัวสำหรับแบบจำลองหนัก และ 15 ตัวสำหรับแบบจำลองเบา) ทั้งนี้ ระบบได้จำกัดไม่ให้ใช้ k-NN ร่วมกับ AdaBoost เนื่องจาก k-NN ไม่รองรับพารามิเตอร์น้ำหนักตัวอย่างที่ AdaBoost ต้องใช้ในการปรับน้ำหนักข้อมูล ระหว่างรอบการฝึกดังที่กล่าวไว้ในหัวข้อ k-NN นอกจากนี้ ในกรณีที่ใช้ร่วมกับ XGBoost ระบบยังได้ปรับสเกลน้ำหนักตัวอย่าง ที่ AdaBoost ส่งมาให้เหมาะสมกับการตีความของ XGBoost โดยเฉพาะ เนื่องจากไลบรารีทั้งสองตีความความหมายของน้ำหนักตัวอย่าง แตกต่างกัน ซึ่งหากไม่ปรับแก้จะทำให้ความแม่นยำของแบบจำลองลดลงอย่างมีนัยสำคัญ

2.2.14 เอ็กซ์ตรีมเกรเดียนท์บูสติง (XGBoost: Extreme Gradient Boosting)



รูปที่ 2.4.10 โลโก้ไลบรารี เอ็กซ์ตรีมเกรเดียนท์บูสติง

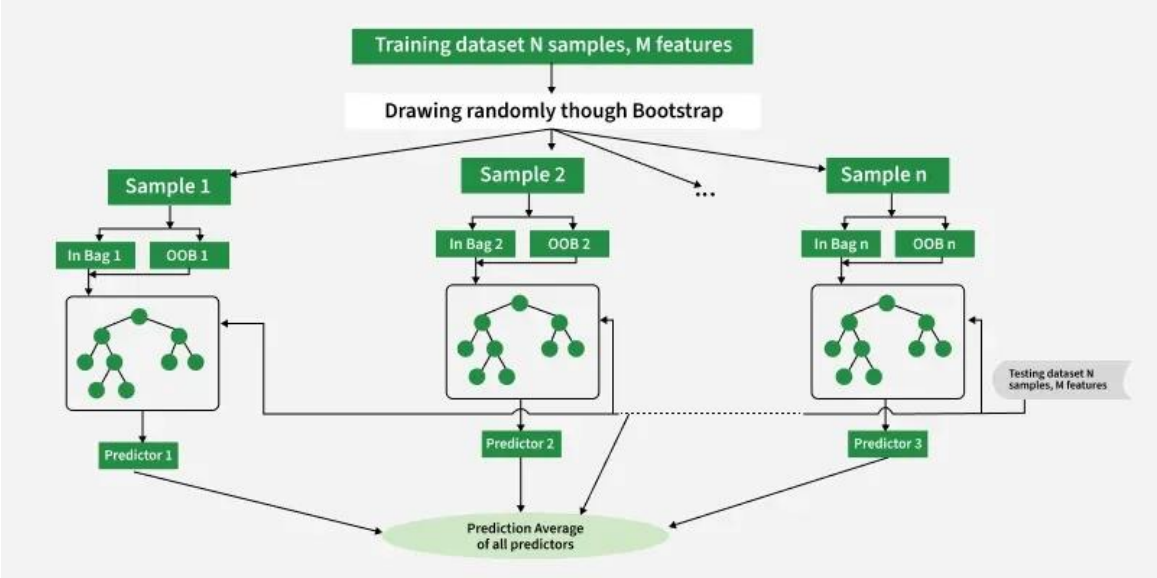
ที่มา (https://www.geeksforgeeks.org/machine-learning/implementation-of-xgboost-extreme-gradient-boosting)

เอ็กซ์ตรีมเกรเดียนท์บูสติง เป็นอัลกอริธึมการเรียนรู้ของเครื่องแบบรวมผลหลายแบบจำลองในกลุ่ม Gradient Boosting ที่ได้รับการปรับปรุงให้มีประสิทธิภาพการประมวลผลสูงและควบคุม Overfitting ได้ดีกว่า Gradient Boosting แบบดั้งเดิม โดยอาศัยหลักการสร้างต้นไม้ตัดสินใจต่อเนื่องกันเป็นลำดับ โดยต้นไม้แต่ละต้นจะเรียนรู้เพื่อแก้ไขความคลาดเคลื่อน (Residual Error) ที่เหลือจากต้นไม้ก่อนหน้า พร้อมทั้งมีกลไกการปรับค่าปกติ (Regularization) ในตัวเพื่อลดความซับซ้อน ของแบบจำลองและป้องกันการเรียนรู้ข้อมูลเฉพาะชุดมากเกินไป

XGBoost เป็นไลบรารีอิสระที่พัฒนาสถาปัตยกรรมสอดคล้องกับรูปแบบมาตรฐานของ scikit-learn (Scikit-learn Compatible API) ทำให้สามารถนำมาใช้งานร่วมกับเครื่องมือของ scikit-learn ได้โดยตรง เช่น การห่อหุ้มด้วย Bagging หรือ AdaBoost อย่างไรก็ตาม ตั้งแต่เวอร์ชัน 1.6 เป็นต้นมา XGBoost กำหนดให้ป้ายกำกับ (Label) ของข้อมูลต้องอยู่ในรูปแบบจำนวนเต็มเรียงจากศูนย์เท่านั้น ไม่รองรับข้อความ (String) เช่น "FIST"/"OPEN" เหมือนโมเดลอื่นในโครงงานนี้ ในโครงงานนี้จึงพัฒนาคลาสตัวห่อหุ้มเฉพาะ (Wrapper Class) ขึ้นมาเพื่อแปลงป้ายกำกับข้อความให้เป็นจำนวนเต็มก่อนป้อนเข้า XGBoost และแปลงผลการทำนายกลับเป็นข้อความ หลังจากนั้น เพื่อให้ทำงานร่วมกับส่วนอื่นของระบบได้โดยไม่ต้องแก้ไขโค้ดจุดอื่นเพิ่มเติม

ในโครงงานนี้กำหนดจำนวนต้นไม้ (n_estimators) เท่ากับ 40 ต้น ความลึกสูงสุด (max_depth) เท่ากับ 4 และอัตราการเรียนรู้ (learning_rate) เท่ากับ 0.3 XGBoost เป็นไลบรารีเสริมที่ต้องติดตั้งเพิ่มเติมนอกเหนือจาก scikit-learn (ผ่านคำสั่ง pip install xgboost) หากเครื่องที่ใช้งานไม่ได้ติดตั้งไลบรารีนี้ไว้ ระบบจะไม่แสดงตัวเลือก XGBoost ในรายการ แบบจำลองที่เลือกได้ แต่จะไม่เกิดข้อผิดพลาดกับการทำงานส่วนอื่นของระบบแต่อย่างใด

2.2.15 แคทบูสต์ (CatBoost: Categorical Boosting)



รูปที่ 2.4.11 โลโก้ไลบรารี CatBoost

ที่มา (https://www.geeksforgeeks.org/machine-learning/catboost-ml)

แคทบูสต์ เป็นอัลกอริธึมการเรียนรู้ของเครื่องในกลุ่ม Gradient Boosting เช่นเดียวกับ XGBoost แต่พัฒนาขึ้นโดยมุ่งเน้น การจัดการกับคุณลักษณะเชิงกลุ่ม (Categorical Feature) ได้อย่างมีประสิทธิภาพโดยไม่ต้องแปลงข้อมูลล่วงหน้า และใช้เทคนิค Ordered Boosting ซึ่งช่วยลดปัญหาการรั่วไหลของข้อมูล (Target Leakage) ที่อาจเกิดขึ้นระหว่างกระบวนการเทรน เมื่อเทียบกับ Gradient Boosting แบบดั้งเดิม ส่งผลให้แบบจำลองมีความทนทานต่อ Overfitting มากขึ้นโดยเฉพาะกับชุดข้อมูลขนาดเล็ก

ในโครงงานนี้ใช้ CatBoost จากไลบรารีต้นฉบับ (CatBoostClassifier) กำหนดจำนวนรอบการวนซ้ำ (iterations) เท่ากับ 60 รอบ และความลึกสูงสุด (depth) เท่ากับ 4 พร้อมปิดการแสดงผล Log ระหว่างเทรน (verbose=False) และปิดการเขียนไฟล์ชั่วคราวลงดิสก์ (allow_writing_files=False) เพื่อไม่ให้กระทบกับพื้นที่จัดเก็บข้อมูลที่จำกัดของ Raspberry Pi 5 เช่นเดียวกับ XGBoost CatBoost เป็นไลบรารีเสริมที่ต้องติดตั้งเพิ่มเติม (ผ่านคำสั่ง pip install catboost) และจะไม่ปรากฏเป็นตัวเลือกในระบบ หากเครื่องที่ใช้งานไม่ได้ติดตั้งไลบรารีนี้ไว้เช่นเดียวกัน ทั้งนี้ CatBoost รองรับป้ายกำกับข้อความได้โดยตรงโดยไม่ต้องใช้ ตัวห่อหุ้มพิเศษเหมือน XGBoost จึงนำมาใช้งานร่วมกับส่วนอื่นของระบบได้ทันที

2.2.16 โมดูลเซนเซอร์สัญญาณกล้ามเนื้อ (EMG Sensor Module (Gravity))



รูปที่ 2.5 เซนเซอร์ตรวจจับสัญญาณกล้ามเนื้อ
ที่มา (https://www.dfrobot.com/product-1661.html)

โมดูลเซนเซอร์สัญญาณกล้ามเนื้อ เป็นองค์ประกอบสำคัญในการตรวจจับสัญญาณไฟฟ้าที่เกิดจากการหดตัวของกล้ามเนื้อ โดยทำหน้าที่รับสัญญาณไฟฟ้าขนาดเล็กจากผิวหนัง ขยายสัญญาณให้มีระดับที่เหมาะสม กรองสัญญาณรบกวนที่ไม่ต้องการ และส่งออกเป็นสัญญาณแอนะล็อกเพื่อให้ระบบสามารถนำไปประมวลผลต่อได้

ในโครงงานนี้ โมดูลเซนเซอร์สัญญาณกล้ามเนื้อถูกติดตั้งบนผิวหนังบริเวณกล้ามเนื้อส่วนแขนที่เหลืออยู่ของผู้ใช้งาน โดยไม่จำเป็นต้องผ่าตัดหรือฝังอุปกรณ์ภายในร่างกาย สัญญาณที่ได้จะถูกส่งผ่านตัวแปลงสัญญาณแอนะล็อกเป็นดิจิทัล เพื่อแปลงข้อมูลให้อยู่ในรูปแบบดิจิทัลสำหรับการประมวลผล บน Raspberry Pi 5

ข้อมูลที่ได้จากเซนเซอร์สามารถแบ่งออกเป็นสองส่วนสำคัญ ได้แก่ ระดับความแรงของการหดตัวของกล้ามเนื้อ ซึ่งสามารถนำไปแปลความหมายเป็นคำสั่งควบคุมการทำงานของมือเทียม และรูปแบบของสัญญาณกล้ามเนื้อที่ใช้ในการฝึกและทดสอบโมเดลการเรียนรู้ของเครื่อง เพื่อจดจำลักษณะการเคลื่อนไหวหรือท่าทางที่ผู้ใช้งานต้องการสั่งงาน

ด้วยคุณสมบัติในการตรวจวัดสัญญาณได้แบบตลอดเวลา มีความแม่นยำสูง และเป็นวิธีที่ไม่ก่อให้เกิดการรุกล้ำต่อร่างกายผู้ใช้งาน โมดูลเซนเซอร์สัญญาณกล้ามเนื้อจึงเป็นอุปกรณ์ที่มีความเหมาะสมสำหรับการนำมาใช้ในระบบควบคุมมือเทียมอัจฉริยะของโครงงานนี้

2.2.17 Servo motor mg996r



รูปที่ 2.6 Servo motor mg996r
ที่มา (https://www.arduitronics.com/product/440/high-torque-servo-motor-mg996r-tower-pro-180-degree)

เซอร์โวมอเตอร์ รุ่น MG996R เป็นมอเตอร์ไฟฟ้าชนิดหนึ่งที่สามารถควบคุมตำแหน่ง มุมการหมุน และความเร็วได้อย่างแม่นยำ โดยอาศัยสัญญาณพัลส์แบบปรับความกว้างพัลส์จากหน่วยควบคุมในการกำหนดตำแหน่งการหมุนของเพลา มอเตอร์ชนิดนี้มีวงจรควบคุมและระบบป้อนกลับ ติดตั้งอยู่ภายในทำให้สามารถรักษาตำแหน่งที่กำหนดไว้ได้อย่างแม่นยำและมีเสถียรภาพ

เซอร์โวมอเตอร์ มีจุดเด่นด้านแรงบิดสูง สามารถรองรับงานที่ต้องการแรงดึงหรือแรงผลักในระดับที่เหมาะสม อีกทั้งยังมีความรวดเร็วในการตอบสนองต่อคำสั่งควบคุม จึงได้รับความนิยมในการประยุกต์ใช้งานด้านหุ่นยนต์ ระบบอัตโนมัติ และอุปกรณ์ช่วยเหลือทางการแพทย์ที่ต้องการการควบคุมตำแหน่งอย่างแม่นยำ

ในโครงงานนี้ใช้เซอร์โวมอเตอร์ เป็นกลไกขับเคลื่อนการเคลื่อนไหวของนิ้วมือเทียม โดยรับสัญญาณควบคุมจากพอร์ตอินพุต–เอาต์พุตอเนกประสงค์ของ Raspberry Pi 5 เพื่อกำหนดมุมการหมุนให้สอดคล้องกับคำสั่งที่ได้จากการวิเคราะห์สัญญาณกล้ามเนื้อ การควบคุมดังกล่าวช่วยให้มือเทียมสามารถงอและเหยียดนิ้วได้อย่างแม่นยำ มีความนุ่มนวลในการเคลื่อนไหว และสามารถหยิบจับวัตถุได้อย่างมีประสิทธิภาพ นอกจากนี้แรงบิดที่สูงของเซอร์โวมอเตอร์ยังช่วยเพิ่มความสามารถในการใช้งานจริงของมือเทียมให้รองรับกิจกรรมในชีวิตประจำวันได้ดียิ่งขึ้น

2.2.18 ราสป์เบอร์รีพาย 5 (Raspberry Pi 5)



รูปที่ 2.7 ไมโครคอมพิวเตอร์ราสป์เบอร์รีพาย 5
ที่มา (https://www.arduitronics.com/product/5874/)

ราสป์เบอร์รีพาย 5 เป็นไมโครคอมพิวเตอร์ขนาดเล็กที่ได้รับการออกแบบตามหลักสถาปัตยกรรมคอมพิวเตอร์ โดยใช้หน่วยประมวลผลแบบเออาร์เอ็ม (ARM Architecture) ซึ่งมีจุดเด่นด้านการใช้พลังงานต่ำและให้ประสิทธิภาพในการประมวลผลสูง ภายในบอร์ดประกอบด้วยหน่วยประมวลผลกลาง (Central Processing Unit: CPU) หน่วยประมวลผลกราฟิก (Graphics Processing Unit: GPU) หน่วยความจำ และวงจรเชื่อมต่ออุปกรณ์ต่าง ๆ ไว้ในแผงวงจรเดียว ทำให้มีขนาดกะทัดรัดและเหมาะสำหรับการพัฒนาระบบสมองกลฝังตัวและงานด้านอินเทอร์เน็ตของสรรพสิ่ง

ราสป์เบอร์รีพาย 5 รองรับระบบปฏิบัติการหลายรูปแบบ และสามารถเชื่อมต่อกับอุปกรณ์ภายนอกผ่านพอร์ตอินพุต–เอาต์พุตอเนกประสงค์ รวมถึงรองรับโพรโทคอลการสื่อสารต่าง ๆ เช่น I²C, UART และ SPI ทำให้สามารถนำไปประยุกต์ใช้งานด้านการควบคุมอุปกรณ์อิเล็กทรอนิกส์ การเก็บรวบรวมข้อมูลจากเซนเซอร์ และการประมวลผลข้อมูลได้อย่างมีประสิทธิภาพ

ในโครงงานนี้ ราสป์เบอร์รีพาย 5 ทำหน้าที่เป็นหน่วยประมวลผลหลักของระบบ โดยรับข้อมูลสัญญาณกล้ามเนื้อจากโมดูลเซนเซอร์ผ่านตัวแปลงสัญญาณแอนะล็อกเป็นดิจิทัล จากนั้นนำข้อมูลเข้าสู่กระบวนการวิเคราะห์ด้วยโมเดลการเรียนรู้ของเครื่อง เพื่อจำแนกคำสั่งการเคลื่อนไหวของผู้ใช้งาน เมื่อได้ผลลัพธ์แล้ว ระบบจะส่งคำสั่งควบคุมไปยังไดรเวอร์มอเตอร์ TB6600 เพื่อขับเคลื่อนกลไกของมือเทียม นอกจากนี้ยังทำหน้าที่บันทึกข้อมูลลงใน Firebase Realtime Database และแสดงผลข้อมูลผ่านเครื่องมือสอบเทียบบนหน้าจอแบบตลอดเวลา ทำให้ผู้ใช้งานสามารถติดตามสถานะการทำงานของระบบได้อย่างต่อเนื่อง

การเลือกใช้ราสป์เบอร์รีพาย 5 ช่วยลดต้นทุนในการพัฒนาระบบ เมื่อเปรียบเทียบกับคอมพิวเตอร์อุตสาหกรรมหรืออุปกรณ์ประมวลผลเฉพาะทาง อีกทั้งยังมีความยืดหยุ่นสูง สามารถพัฒนาต่อยอดและเพิ่มความสามารถของระบบได้ในอนาคต

2.2.19 เทคโนโลยีการพิมพ์สามมิติ (3D Printing)



รูปที่ 2.8 เครื่องพิมพ์สามมิติสำหรับสร้างโครงมือเทียม
ที่มา (https://www.creality.com/)

เทคโนโลยีการพิมพ์สามมิติ เป็นกระบวนการสร้างชิ้นงานสามมิติด้วยการเพิ่มวัสดุทีละชั้นตามแบบจำลองดิจิทัลที่ออกแบบไว้ กระบวนการดังกล่าวอาศัยข้อมูลจากซอฟต์แวร์ออกแบบโดยใช้คอมพิวเตอร์ช่วย (Computer-Aided Design: CAD) เพื่อกำหนดรูปร่าง ขนาด และรายละเอียดของชิ้นงานก่อนเข้าสู่กระบวนการผลิตจริง

หลักการสำคัญของเทคโนโลยีการพิมพ์สามมิติแตกต่างจากกระบวนการผลิตแบบดั้งเดิมที่มักใช้การตัดหรือขึ้นรูปวัสดุ โดยจะสร้างชิ้นงานจากการสะสมวัสดุเป็นชั้น ๆ จนได้รูปร่างตามที่กำหนด วิธีการดังกล่าวช่วยลดการสูญเสียวัสดุ สามารถผลิตชิ้นงานที่มีรูปทรงซับซ้อนได้ง่าย และรองรับการผลิตชิ้นงานเฉพาะบุคคลได้อย่างมีประสิทธิภาพ นอกจากนี้ยังช่วยลดต้นทุนในการสร้างต้นแบบและลดระยะเวลาในการพัฒนาผลิตภัณฑ์เมื่อเทียบกับการผลิตที่ต้องใช้แม่พิมพ์

ในโครงงานนี้ใช้เทคโนโลยีการพิมพ์สามมิติในการผลิตโครงสร้างของนิ้วมือและฝ่ามือเทียม โดยเลือกใช้พลาสติกพอลิแลกติกแอซิด (Polylactic Acid: PLA) เป็นวัสดุหลัก เนื่องจากมีน้ำหนักเบา มีความแข็งแรงเพียงพอต่อการใช้งาน และเป็นวัสดุที่เป็นมิตรต่อสิ่งแวดล้อม การออกแบบชิ้นส่วนของมือเทียมมุ่งเน้นการปรับแต่งให้เหมาะสมกับสรีระของผู้ใช้งานแต่ละบุคคลเพื่อเพิ่มความสะดวกสบายและประสิทธิภาพในการใช้งาน ซึ่งถือเป็นข้อได้เปรียบสำคัญเมื่อเปรียบเทียบกับมือเทียมที่ผลิตจากโรงงานซึ่งมักมีขนาดและรูปแบบมาตรฐาน

2.2.20 ไฟร์เบส (Firebase)



รูปที่ 2.9 แพลตฟอร์ม Firebase สำหรับจัดเก็บข้อมูลผู้ใช้บนคลาวด์
ที่มา (https://firebase.google.com/)

ไฟร์เบส เป็นแพลตฟอร์มสำหรับการพัฒนาแอปพลิเคชันบนคลาวด์ (Cloud Application Development Platform) ที่พัฒนาโดย Google ซึ่งให้บริการเครื่องมือและโครงสร้างพื้นฐานสำหรับการพัฒนาแอปพลิเคชันทั้งบนเว็บและอุปกรณ์เคลื่อนที่ โดยหนึ่งในบริการที่ได้รับความนิยมคือฐานข้อมูลไฟร์เบสแบบตลอดเวลา (Firebase Realtime Database) ซึ่งเป็นฐานข้อมูลแบบไม่มีโครงสร้างตาราง (NoSQL Database) ที่สามารถซิงโครไนซ์ข้อมูลระหว่างอุปกรณ์ต่าง ๆ ได้อย่างต่อเนื่อง

ฐานข้อมูลไฟร์เบสแบบตลอดเวลาจัดเก็บข้อมูลในรูปแบบต้นไม้เจสัน (JSON Tree) ซึ่งมีโครงสร้างที่ยืดหยุ่นและสามารถเข้าถึงข้อมูลได้อย่างรวดเร็ว ส่งผลให้เหมาะสำหรับระบบที่ต้องมีการรับส่งและอัปเดตข้อมูลอยู่ตลอดเวลา นอกจากนี้ยังรองรับการทำงานแบบออฟไลน์ โดยสามารถจัดเก็บข้อมูลชั่วคราวภายในอุปกรณ์ และทำการซิงโครไนซ์ข้อมูลกลับไปยังฐานข้อมูลโดยอัตโนมัติเมื่อมีการเชื่อมต่ออินเทอร์เน็ตอีกครั้ง ช่วยเพิ่มความเสถียรและความน่าเชื่อถือของระบบในสภาวะที่เครือข่ายไม่เสถียร

ในโครงงานนี้ใช้ฐานข้อมูลไฟร์เบสแบบตลอดเวลาในการจัดเก็บข้อมูลโปรไฟล์การสอบเทียบของผู้ใช้งานแต่ละคน ซึ่งประกอบด้วยรูปแบบสัญญาณกล้ามเนื้อที่ได้จากกระบวนการสอบเทียบ พารามิเตอร์ของโมเดลการเรียนรู้ของเครื่องที่ผ่านการฝึกแล้ว และข้อมูลประวัติการใช้งานของระบบ ข้อมูลทั้งหมดจะถูกส่งจาก Raspberry Pi 5 ไปยังระบบคลาวด์ผ่านไลบรารี pyrebase เพื่อให้สามารถจัดเก็บและเรียกใช้งานได้จากทุกที่ที่มีการเชื่อมต่ออินเทอร์เน็ต

การนำไฟร์เบสมาใช้ในโครงงานช่วยให้ผู้ดูแลระบบสามารถติดตามสถานะการทำงานและประวัติการใช้งานของมือเทียมจากระยะไกล รวมทั้งสามารถปรับปรุงข้อมูลการสอบเทียบหรืออัปเดตพารามิเตอร์ของโมเดลผ่านระบบคลาวด์ได้โดยไม่จำเป็นต้องเชื่อมต่อกับอุปกรณ์โดยตรง ส่งผลให้การดูแลรักษาและพัฒนาระบบในระยะยาวมีความสะดวก ยืดหยุ่น และมีประสิทธิภาพมากยิ่งขึ้น

2.2.21 งานวิจัยและโครงงานที่เกี่ยวข้อง (Related Works)

คมสันต์ เหล็มมะ และคณะ (2561) ได้ทำการศึกษาวิจัยเชิงพรรณนาเรื่องการบาดเจ็บที่เกี่ยวเนื่องจากการทำงานและพฤติกรรมการทำงานที่ปลอดภัยของพนักงานโรงงานอุตสาหกรรมผลิตชิ้นส่วนรถยนต์ในจังหวัดระยอง จำนวน 386 คน โดยเก็บรวบรวมข้อมูลด้วยแบบสอบถามและวิเคราะห์ข้อมูลด้วยสถิติเชิงพรรณนา ผลการศึกษาพบว่าในช่วง 3 เดือนที่ผ่านมากลุ่มตัวอย่างเคยได้รับบาดเจ็บจากการทำงานร้อยละ 6.5 โดยพบการบาดเจ็บมากที่สุดในขั้นตอนการตัด ร้อยละ 36.0 และอวัยวะที่ได้รับบาดเจ็บมากที่สุดคือนิ้วมือ ร้อยละ 53.8 ซึ่งส่วนใหญ่ร้อยละ 76.9 เป็นการบาดเจ็บเล็กน้อยที่ไม่ต้องหยุดงาน สาเหตุของการบาดเจ็บส่วนใหญ่เกิดจากชิ้นงานหรือสิ่งของตัด บาด ทิ่มแทง ร้อยละ 61.5 ส่วนพฤติกรรมการทำงานที่ปลอดภัยโดยรวมของกลุ่มตัวอย่างอยู่ในระดับปานกลาง ร้อยละ 74.9 ทั้งด้านการใช้อุปกรณ์ป้องกันอันตรายส่วนบุคคล การใช้เครื่องมือเครื่องจักรอย่างถูกวิธี และการปฏิบัติตามกฎระเบียบความปลอดภัยในการทำงาน ผู้วิจัยเสนอแนะให้พยาบาลอาชีวอนามัยและทีมงานที่เกี่ยวข้องให้ความสำคัญกับการเสริมสร้างพฤติกรรมการทำงานที่ปลอดภัยแก่พนักงานในโรงงานอุตสาหกรรมที่ต้องทำงานกับเครื่องจักรและอุปกรณ์มีคมอย่างต่อเนื่อง งานวิจัยนี้สะท้อนให้เห็นว่าการบาดเจ็บที่นิ้วมือและมือจากการทำงานกับเครื่องจักรในภาคอุตสาหกรรมยังคงเป็นปัญหาสำคัญที่อาจนำไปสู่ความพิการหรือการสูญเสียอวัยวะส่วนปลายของแขนได้ ซึ่งเป็นข้อมูลพื้นฐานสำคัญที่สนับสนุนความจำเป็นของการพัฒนามือเทียมควบคุมด้วยสัญญาณกล้ามเนื้อในโครงงานนี้ เพื่อรองรับผู้ที่สูญเสียอวัยวะมือหรือนิ้วมือจากอุบัติเหตุในการทำงาน

พุดตาน พันธุเณร และคณะ (2561) ได้ศึกษาการวิเคราะห์และพยากรณ์ความต้องการกำลังคนด้านสุขภาพสำหรับระบบบริการระดับทุติยภูมิของประเทศไทยในปี พ.ศ. 2569 โดยประยุกต์ใช้แบบจำลองอ้างอิงการใช้บริการ (Utilization-Based Model) ร่วมกับแนวคิดการวิเคราะห์กำลังคนด้านสุขภาพของ Segal และการวิเคราะห์ความอ่อนไหว เพื่อประเมินความต้องการบุคลากรทางการแพทย์ในอนาคต จากการศึกษาพบว่า ความต้องการกำลังคนด้านสุขภาพในทุกสาขาวิชาชีพมีแนวโน้มเพิ่มขึ้นจากปี พ.ศ. 2556 โดยเฉลี่ยประมาณร้อยละ 9 อันเป็นผลมาจากการเปลี่ยนแปลงโครงสร้างประชากรเข้าสู่สังคมผู้สูงอายุ ส่งผลให้ความต้องการใช้บริการทางการแพทย์และการฟื้นฟูสมรรถภาพเพิ่มสูงขึ้น โดยเฉพาะบุคลากรด้านกายภาพบำบัดและการฟื้นฟูผู้พิการ

งานวิจัยนี้มีความเกี่ยวข้องกับโครงงาน เนื่องจากสะท้อนให้เห็นถึงแนวโน้มการเพิ่มขึ้นของผู้สูงอายุและผู้พิการที่ต้องการการฟื้นฟูสมรรถภาพ ขณะที่จำนวนบุคลากรทางการแพทย์และนักกายภาพบำบัดมีอยู่อย่างจำกัด ดังนั้นการพัฒนามือเทียมควบคุมด้วยสัญญาณกล้ามเนื้อที่มีต้นทุนต่ำและใช้งานได้สะดวก จึงเป็นแนวทางหนึ่งที่สามารถช่วยสนับสนุนการฟื้นฟูสมรรถภาพของผู้พิการ ลดภาระของบุคลากรทางการแพทย์ และเพิ่มโอกาสในการเข้าถึงอุปกรณ์ช่วยเหลือของผู้ใช้งานในอนาคต

มณียฉัตร มาสมภพ (2546) ได้ศึกษาปัญหา ความต้องการ และระดับความพึงพอใจของผู้มารับบริการด้านเบี้ยยังชีพ เงินสงเคราะห์ครอบครัว และกายอุปกรณ์ ณ สำนักส่งเสริมและพิทักษ์คนพิการ โดยใช้การวิเคราะห์ตารางไขว้และสถิติไคสแควร์ (Chi-Square) เพื่อศึกษาความสัมพันธ์ระหว่างปัจจัยส่วน

บุคคลกับความรู้ ความต้องการ ปัญหา และความพึงพอใจของผู้รับบริการ ผลการศึกษาพบว่าผู้มารับบริการส่วนใหญ่เป็นผู้พิการทางกายหรือการเคลื่อนไหว และมีความพึงพอใจต่อสถานที่และการให้บริการของเจ้าหน้าที่ในระดับสูง อย่างไรก็ตาม ผู้รับบริการมีความพึงพอใจต่ำที่สุดในด้านการได้รับข้อมูลข่าวสารเกี่ยวกับสวัสดิการ และยังพบว่ากายอุปกรณ์เป็นบริการที่มีผู้มาขอรับน้อยกว่าสวัสดิการประเภทอื่น นอกจากนี้ ปัจจัยด้านเพศ อายุ ระดับการศึกษา อาชีพ และประเภทความพิการ มีความสัมพันธ์กับความรู้ความต้องการ และปัญหาในการเข้าถึงบริการอย่างมีนัยสำคัญทางสถิติ

งานวิจัยนี้มีความเกี่ยวข้องกับโครงงาน เนื่องจากสะท้อนให้เห็นถึงข้อจำกัดในการเข้าถึงกายอุปกรณ์และข้อมูลด้านสวัสดิการของผู้พิการในประเทศไทย ซึ่งยังไม่สามารถตอบสนองความต้องการได้อย่างทั่วถึง ข้อมูลดังกล่าวสนับสนุนความสำคัญของการพัฒนามือเทียมควบคุมด้วยสัญญาณกล้ามเนื้อที่มีต้นทุนเหมาะสมและเข้าถึงได้ง่าย เพื่อเพิ่มทางเลือกในการใช้งานกายอุปกรณ์สำหรับผู้พิการแขนขาด และช่วยยกระดับคุณภาพชีวิตของผู้ใช้งานในระยะยาว

Carey, S. L. และคณะ (2015) ได้ทำการทบทวนวรรณกรรมอย่างเป็นระบบเพื่อเปรียบเทียบความแตกต่างระหว่างมือเทียมแบบควบคุมด้วยสัญญาณกล้ามเนื้อ (Myoelectric Prosthesis) และมือเทียมแบบควบคุมด้วยแรงจากร่างกาย (Body-Powered Prosthesis) โดยทำการสืบค้นข้อมูลจากฐานข้อมูลทางวิชาการจำนวน 9 แหล่ง ได้แก่ PubMed, CINAHL, RECAL Legacy, Cochrane Database of Systematic Reviews, Cochrane Clinical Trials Registry, EMBASE, PMC-NIH, Web of Science และ Google Scholar จากนั้นคัดกรองบทความที่เกี่ยวข้องจำนวน 462 ฉบับตามเกณฑ์การคัดเข้าและคัดออก จนเหลือ 31 ฉบับสำหรับการวิเคราะห์เชิงคุณภาพ และสรุปเป็นข้อความหลักฐานเชิงประจักษ์ (Empirical Evidence Statement: EES) จำนวน 11 ประเด็น

ผลการศึกษาพบว่ามือเทียมแบบควบคุมด้วยแรงจากร่างกายมีข้อได้เปรียบในด้านความทนทาน ใช้ระยะเวลาในการฝึกใช้งานน้อยกว่า ต้องการการปรับแต่งและการบำรุงรักษาน้อยกว่า รวมถึงให้ข้อมูลป้อนกลับเชิงสัมผัส (Sensory Feedback) ที่ชัดเจน เนื่องจากระบบสายเคเบิลและฮาร์เนสช่วยให้ผู้ใช้รับรู้ระดับการเปิด–ปิดของมือเทียมได้แม้ในสภาวะที่ไม่สามารถมองเห็นได้โดยตรง

ในขณะเดียวกัน มือเทียมแบบควบคุมด้วยสัญญาณกล้ามเนื้อมีข้อได้เปรียบด้านความสวยงาม เนื่องจากมีรูปลักษณ์ใกล้เคียงมือจริงมากกว่า เหมาะสำหรับงานที่ต้องใช้แรงไม่มาก และมีแนวโน้มช่วยลดอาการปวดจากแขนขาที่ไม่มีอยู่จริงเมื่อมีการใช้งานอย่างต่อเนื่อง อย่างไรก็ตาม ผลการศึกษาพบว่าอัตราการเลิกใช้งาน (Rejection Rate) ของมือเทียมทั้งสองประเภทไม่แตกต่างกันอย่างชัดเจน โดยมือเทียมแบบแรงจากร่างกายมีอัตราการเลิกใช้งานเฉลี่ยร้อยละ 26 และมือเทียมแบบควบคุมด้วยสัญญาณกล้ามเนื้อมีอัตราเฉลี่ยร้อยละ 23

งานวิจัยสรุปว่าหลักฐานเชิงประจักษ์ในปัจจุบันยังไม่เพียงพอที่จะระบุได้ว่ามือเทียมประเภทใดมีความเหนือกว่าอย่างชัดเจน การเลือกใช้งานจึงควรพิจารณาตามความต้องการเฉพาะบุคคล ลักษณะการใช้งาน และบริบทของผู้ใช้เป็นสำคัญ ซึ่งข้อค้นพบนี้มีความเกี่ยวข้องกับโครงงาน เนื่องจากสนับสนุน

แนวคิดในการพัฒนามือเทียมควบคุมด้วยสัญญาณกล้ามเนื้อที่ไม่เพียงคำนึงถึงประสิทธิภาพการทำงาน แต่ยังต้องให้ความสำคัญกับความสวยงาม ความเหมาะสม และความต้องการของผู้ใช้งานควบคู่กันไปด้วย

Chadwell, A. และคณะ (2016) ได้กล่าวว่าผู้ใช้งานมือเทียมที่ควบคุมด้วยสัญญาณกล้ามเนื้อมักประสบปัญหาในการควบคุมอุปกรณ์ ซึ่งอาจนำไปสู่พฤติกรรมการใช้งานแบบเฉื่อยชา หรือการเลิกใช้งานโดยสิ้นเชิง และส่งผลให้เกิดการใช้งานแขนข้างที่สมบูรณ์มากเกินไป ในทางกลับกัน ระบบมือเทียมที่ใช้งานจริงในเชิงคลินิกส่วนใหญ่ยังเป็นระบบวงเปิด ซึ่งไม่มีข้อมูลป้อนกลับกลับไปยังผู้ใช้งานอย่างเพียงพอ

แม้ว่าจะมีการพัฒนาระบบป้อนกลับเชิงสัมผัส เพื่อเพิ่มประสิทธิภาพการควบคุมแบบวงปิด แต่ผลการศึกษาบางส่วนพบว่าความสามารถในการคาดเดาการตอบสนองของมือเทียม อาจมีความสำคัญไม่แพ้หรือมากกว่าการมีข้อมูลป้อนกลับโดยตรง ดังนั้นผู้วิจัยจึงได้พัฒนาโพรโทคอลสำหรับประเมินปัจจัยสำคัญในระบบควบคุมมือเทียม 2 ด้าน ได้แก่ ทักษะในการสร้างสัญญาณไฟฟ้ากล้ามเนื้อของผู้ใช้ และความไม่แน่นอนของระบบรับสัญญาณ

การประเมินทักษะดังกล่าววัดจากความเร็วและความแม่นยำในการสร้างสัญญาณ โดยใช้แบบทดสอบเวลาตอบสนองอย่างง่าย และเวลาตอบสนองแบบเลือก ตามแนวคิดการลบของดอนเดอร์ส เพื่อวิเคราะห์ระยะเวลาที่ใช้ในการตัดสินใจของผู้ใช้งาน ส่วนความไม่แน่นอนของระบบเกิดจากความสัมพันธ์ระหว่างอิเล็กโทรดกับผิวหนังและความกระชับของเบ้าซ็อกเก็ตซึ่งส่งผลต่อความเสถียรของสัญญาณที่ตรวจวัดได้

ปัจจัยทั้งสองถูกนำไปเชื่อมโยงกับความสามารถในการใช้งานจริง ซึ่งประเมินผ่านภารกิจการหยิบจับวัตถุทรงกระบอกหลายขั้นตอน โดยวัดอัตราความสำเร็จ ระยะเวลาในการทำภารกิจ คุณภาพการเคลื่อนไหวด้วยเซนเซอร์วัดความเร่ง และพฤติกรรมการมองด้วยเครื่องติดตามการเคลื่อนไหวของดวงตา รวมถึงการใช้งานในชีวิตประจำวัน ที่วัดผ่านเครื่องวัดความเคลื่อนไหวที่สวมบริเวณข้อมือทั้งสองข้างเป็นระยะเวลา 1 สัปดาห์

ผลการศึกษานำร่องพบว่าผู้ใช้งานมือเทียมมีเวลาตอบสนองเฉลี่ยอยู่ที่ประมาณ 270–420 มิลลิวินาที ซึ่งช้ากว่าค่าของกล้ามเนื้อปกติที่ประมาณ 190 มิลลิวินาที นอกจากนี้ยังพบว่าความไม่เสถียรของเบ้าซ็อกเก็ตอาจทำให้เกิดการตอบสนองที่ไม่พึงประสงค์ เช่น การสั่งเปิดมือแต่กลับเกิดการปิดมือแทนในบางครั้ง

งานวิจัยนี้สรุปว่าทั้งทักษะของผู้ใช้ในการสร้างสัญญาณกล้ามเนื้อและความเสถียรของระบบรับสัญญาณมีผลอย่างมากต่อประสิทธิภาพการควบคุมมือเทียม ซึ่งมีความเกี่ยวข้องโดยตรงกับโครงงานนี้ในการออกแบบกระบวนการสอบเทียบสัญญาณกล้ามเนื้อ (Calibration) และการจัดเก็บข้อมูลโพรไฟล์เฉพาะบุคคลในฐานข้อมูล เพื่อเพิ่มความแม่นยำและความเสถียรในการควบคุมมือเทียมต้นแบบในระบบของโครงงาน

ten Kate, J. และคณะ (2017) ได้ทำการทบทวนวรรณกรรมเกี่ยวกับมือเทียมแขนส่วนบนที่ผลิตด้วยเทคโนโลยีการพิมพ์สามมิติ โดยรวบรวมข้อมูลจากฐานข้อมูลทางวิชาการ Scopus และ Web of Science ร่วมกับแหล่งข้อมูลออนไลน์ที่เกี่ยวข้องกับเทคโนโลยีการพิมพ์สามมิติ ได้แก่

enablingthefuture.org, 3dprint.com และ 3ders.org จนได้อุปกรณ์มือเทียมที่นำมาวิเคราะห์ทั้งสิ้น 58 ชิ้น

ผลการจำแนกประเภทพบว่าอุปกรณ์เหล่านี้แบ่งตามระดับการตัดแขนได้เป็น มือหรือมือบางส่วน 18 ชิ้น แขนส่วนล่าง 37 ชิ้น และแขนส่วนบน 3 ชิ้น ขณะเดียวกันเมื่อแบ่งตามลักษณะการขับเคลื่อน พบว่าเป็นแบบพาสซิฟอยู่กับที่ 2 ชิ้น แบบพาสซิฟปรับได้ 1 ชิ้น แบบควบคุมด้วยแรงจากร่างกาย 32 ชิ้น และแบบขับเคลื่อนจากภายนอก 23 ชิ้น โดยในกลุ่มหลังส่วนใหญ่ใช้ระบบควบคุมด้วยสัญญาณกล้ามเนื้อ จำนวน 20 ชิ้น

ด้านน้ำหนักของอุปกรณ์พบว่ามีเพียง 11 ชิ้นจากทั้งหมด 58 ชิ้นที่ระบุน้ำหนักอย่างชัดเจน โดยมีช่วงน้ำหนักตั้งแต่ 71 กรัมจนถึง 2,000 กรัมสำหรับแขนเทียมเต็มรูปแบบ ซึ่งใกล้เคียงกับน้ำหนักเฉลี่ยของมือมนุษย์ที่ประมาณ 400±90 กรัม ในด้านกลไกการทำงานพบว่าส่วนใหญ่ใช้สายเคเบิลหรือเชือกในการงอนิ้ว (Flexion) และใช้กลไก หรือยางยืดในการเหยียดนิ้ว ตามหลักการปิดด้วยความสมัครใจ

ในด้านเทคโนโลยีการผลิต พบว่าเทคนิคการพิมพ์แบบหลอมเส้นพลาสติก เป็นวิธีที่ได้รับความนิยมสูงที่สุด โดยมีจำนวนถึง 46 จาก 58 ชิ้น เนื่องจากสามารถใช้เครื่องพิมพ์ราคาประหยัดได้ประมาณ 2,000 ดอลลาร์สหรัฐ และใช้งานได้ง่าย แม้จะมีข้อจำกัดด้านความละเอียดของพื้นผิวเมื่อเทียบกับเทคนิคอื่น วัสดุที่นิยมใช้ ได้แก่ ABS และ PLA สำหรับต้นทุนการผลิต พบว่าอุปกรณ์ที่มีการระบุข้อมูลต้นทุนมีค่าใช้จ่ายอยู่ระหว่าง 5–500 ดอลลาร์สหรัฐ ซึ่งต่ำกว่ามือเทียมเชิงพาณิชย์แบบควบคุมด้วยแรงจากร่างกาย (4,000–10,000 ดอลลาร์สหรัฐ) และมือเทียมควบคุมด้วยสัญญาณกล้ามเนื้อเชิงพาณิชย์ (25,000–75,000 ดอลลาร์สหรัฐ) อย่างมาก

อย่างไรก็ตาม งานวิจัยยังระบุว่ายังขาดหลักฐานเชิงประจักษ์เกี่ยวกับความคงทน การยอมรับของผู้ใช้งาน และประสิทธิภาพในการใช้งานจริงของมือเทียมที่ผลิตด้วยการพิมพ์สามมิติ อีกทั้งยังชี้ว่าการพิมพ์สามมิติไม่ได้มีต้นทุนต่ำกว่าวิธีการผลิตแบบดั้งเดิมเสมอไป เช่น การฉีดขึ้นรูป แต่มีข้อได้เปรียบสำคัญในด้านการออกแบบเฉพาะบุคคล เช่น รูปทรง ขนาด สี และความเหมาะสมกับผู้ใช้งาน โดยไม่ต้องปรับเปลี่ยนกระบวนการผลิตเชิงอุตสาหกรรม

งานวิจัยนี้มีความเกี่ยวข้องกับโครงงาน เนื่องจากสนับสนุนการเลือกใช้เทคโนโลยีการพิมพ์สามมิติแบบหลอมเส้นพลาสติก (FDM) ร่วมกับวัสดุ PLA ในการผลิตโครงสร้างมือเทียมต้นแบบ ด้วยเหตุผลด้านต้นทุนต่ำ ความสะดวกในการเข้าถึง และความสามารถในการปรับแต่งให้เหมาะสมกับสรีระของผู้ใช้งานแต่ละบุคคล

Edwards, A. L. และคณะ (2016) ได้ทำการศึกษาการประยุกต์ใช้การเรียนรู้ของเครื่อง ในการควบคุมมือเทียมควบคุมด้วยสัญญาณกล้ามเนื้อแบบตลอดเวลา) โดยออกแบบการทดลองเชิงกรณีศึกษา (Case Series) เพื่อเปรียบเทียบวิธีการควบคุมแบบสลับฟังก์ชัน จำนวน 2 รูปแบบ ได้แก่ การควบคุมแบบไม่ปรับตัว และการควบคุมแบบปรับตัวได้ ซึ่งอาศัยการเรียนรู้และการพยากรณ์แบบตลอดเวลาด้วยเทคนิค General Value Functions ที่อยู่ภายใต้กรอบการเรียนรู้แบบเสริมกำลัง (Reinforcement Learning)

การทดลองแบ่งออกเป็นสองส่วน ส่วนแรกให้ผู้พิการแขนขาดระดับต้นแขน 1 คน และผู้ที่มีร่างกายสมบูรณ์ 1 คน ทดลองควบคุมแขนกลในภารกิจพื้นฐาน ส่วนที่สองให้ผู้เข้าร่วมที่มีร่างกายสมบูรณ์ 3 คน ควบคุมแขนกล Bento Arm ซึ่งมี 5 องศาอิสระ ในภารกิจ Box-and-Blocks ที่มีความซับซ้อนมากขึ้น โดยวัดจำนวนครั้งและระยะเวลาในการสลับฟังก์ชันของข้อต่อแขนกลระหว่างการทำภารกิจ

ผลการศึกษาพบว่าการควบคุมแบบปรับตัวได้สามารถลดจำนวนครั้งและระยะเวลาในการสลับฟังก์ชันลงได้อย่างมีนัยสำคัญเมื่อเทียบกับการควบคุมแบบเดิมในทั้งสองภารกิจ โดยในภารกิจพื้นฐานผู้พิการแขนขาดสามารถลดเวลาในการสลับฟังก์ชันได้เฉลี่ยประมาณ 20 วินาทีต่อการทดลองระยะเวลา 3 นาที หรือคิดเป็นร้อยละ 11 ของเวลารวม ส่วนในภารกิจที่ซับซ้อนขึ้น ผู้ใช้งานสามารถลดระยะเวลาในการทำภารกิจได้สูงสุดประมาณร้อยละ 20 ในช่วงท้ายของการทดลอง

งานวิจัยนี้สรุปว่าการเรียนรู้และการพยากรณ์เจตนาของผู้ใช้แบบตลอดเวลามีศักยภาพในการลดภาระการควบคุม และเพิ่มประสิทธิภาพในการใช้งานมือเทียมที่มีหลายองศาอิสระ โดยข้อค้นพบดังกล่าวมีความเกี่ยวข้องกับโครงงานนี้ เนื่องจากสนับสนุนแนวทางการนำเทคนิคการเรียนรู้ของเครื่องมาประยุกต์ใช้ร่วมกับการประมวลผลสัญญาณกล้ามเนื้อ เพื่อจำแนกเจตนาการเคลื่อนไหวของผู้ใช้บน Raspberry Pi 5 ให้มีความแม่นยำและตอบสนองได้เหมาะสมมากขึ้น แทนการใช้การควบคุมแบบสลับฟังก์ชันเพียงอย่างเดียว

Igual, C. และคณะ (2019) ได้ทำการทบทวนวรรณกรรมอย่างเป็นระบบเกี่ยวกับการควบคุมมือเทียมแขนส่วนบนด้วยสัญญาณคลื่นไฟฟ้ากล้ามเนื้อ โดยนำเสนอกรอบแนวคิดของวงรอบการควบคุมแบบปิด ซึ่งประกอบด้วย 4 ขั้นตอนหลัก ได้แก่ การเก็บสัญญาณกล้ามเนื้อจากกล้ามเนื้อแขนส่วนที่เหลือ การประมวลผลสัญญาณด้วยเทคนิคการเรียนรู้ของเครื่อง เพื่อแปลงเป็นสัญญาณควบคุม การประมาณผลลัพธ์การเคลื่อนไหวของมือเทียม และการให้ข้อมูลป้อนกลับแก่ผู้ใช้งาน

ในด้านการเก็บสัญญาณ ผู้วิจัยรายงานว่างานวิจัยส่วนใหญ่ใช้จำนวนช่องสัญญาณกล้ามเนื้อระหว่าง 4–12 ช่อง โดยมีความถี่การสุ่มตัวอย่างที่ประมาณ 1,000 เฮิรตซ์ ตามทฤษฎี Nyquist–Shannon และมีการกำหนดขนาดหน้าต่างสัญญาณ สำหรับการสกัดคุณลักษณะอยู่ในช่วง 100–125 มิลลิวินาที เนื่องจากหน้าต่างที่มีขนาดเล็กเกินไป (ต่ำกว่า 100 มิลลิวินาที) จะส่งผลให้ประสิทธิภาพของระบบลดลง

ในขั้นตอนการเรียนรู้ พบว่าวิธีการจำแนกประเภท เป็นแนวทางที่นิยมในงานประยุกต์จริง เนื่องจากใช้ทรัพยากรคำนวณต่ำและมีความทนทาน โดยมักใช้ฟีเจอร์ในโดเมนเวลา เช่น Root Mean Square (RMS) ซึ่งเหมาะสำหรับการหดตัวของกล้ามเนื้อระดับสูง และ Mean Absolute Value (MAV) ซึ่งเหมาะสำหรับการหดตัวระดับต่ำหรือภาวะกล้ามเนื้อล้า ร่วมกับตัวจำแนก Linear Discriminant Analysis (LDA) ซึ่งให้ความสมดุลระหว่างความแม่นยำและความซับซ้อนในการประมวลผล ขณะที่วิธีการถดถอย (Regression) แม้จะให้การควบคุมที่ต่อเนื่องและเป็นธรรมชาติมากกว่า แต่ยังมีข้อจำกัดในการควบคุมที่มีหลายองศาอิสระ

นอกจากนี้ งานวิจัยยังชี้ให้เห็นปัญหาความไม่นิ่งของสัญญาณกล้ามเนื้อ ในสภาวะการใช้งานจริง ซึ่งเกิดจากการเปลี่ยนตำแหน่งแขน การเลื่อนของอิเล็กโทรด เหงื่อ และความล้าของกล้ามเนื้อ ส่งผลให้โมเดลที่มีประสิทธิภาพสูงในสภาพแวดล้อมควบคุมอาจทำงานได้ลดลงเมื่อใช้งานจริงนอกห้องปฏิบัติการ

งานวิจัยสรุปว่าช่องว่างระหว่างงานวิจัยเชิงวิชาการและการใช้งานเชิงพาณิชย์ยังคงเป็นประเด็นสำคัญ พร้อมเสนอให้พัฒนาโพรโทคอลการสอบเทียบที่ใช้งานง่ายสำหรับผู้ใช้ทั่วไป ซึ่งมีความเกี่ยวข้องโดยตรงกับโครงงานนี้ในการกำหนดแนวทางเลือกจำนวนช่องสัญญาณ ความถี่การสุ่มตัวอย่าง ขนาดหน้าต่างสัญญาณ และการเลือกฟีเจอร์ในโดเมนเวลาสำหรับการใช้งานไลบรารี scikit-learn บน Raspberry Pi 5 รวมถึงการออกแบบกระบวนการสอบเทียบเพื่อเพิ่มความเสถียรของระบบในสภาวะการใช้งานจริง

Segura, D. และคณะ (2024) ได้ทำการทบทวนวรรณกรรมอย่างเป็นระบบเกี่ยวกับมือเทียมแขนส่วนบน โดยจำแนกตามระดับการตัดแขน (Level of Amputation) ได้แก่ ระดับการตัดผ่านกระดูกฝ่ามือ ระดับการตัดผ่านข้อมือ ระดับการตัดผ่านกระดูกปลายแขนใต้ข้อศอก และระดับการตัดผ่านกระดูกต้นแขนเหนือข้อศอก โดยทำการสืบค้นข้อมูลจากฐานข้อมูลทางวิชาการ ได้แก่ Scopus, IEEE Xplore, Springer, PubMed, Frontiers และ Espacenet ในช่วงปี ค.ศ. 2018–2023 ตามแนวทาง PRISMA จนได้อุปกรณ์มือเทียมที่นำมาวิเคราะห์ทั้งสิ้น 90 ชิ้น ซึ่งประกอบด้วยบทความวิชาการ สิทธิบัตร และผลิตภัณฑ์เชิงพาณิชย์

ผลการศึกษาพบว่าวิธีการควบคุมที่ได้รับความนิยมสูงที่สุดคือการควบคุมด้วยสัญญาณกล้ามเนื้อ (Myoelectric Control) คิดเป็นร้อยละ 44.44 ของอุปกรณ์ทั้งหมด รองลงมาคือระบบที่ไม่มีการควบคุมอัตโนมัติร้อยละ 22.22 และระบบกลไกล้วนร้อยละ 13.33 โดยพบว่าระดับการตัดแขนใต้ข้อศอกเป็นกลุ่มที่มีการพัฒนามากที่สุดจำนวน 40 ชิ้น เนื่องจากมีพื้นที่เพียงพอสำหรับติดตั้งองค์ประกอบของระบบโดยไม่ต้องใช้โครงสร้างเสริมเพิ่มเติม

ในด้านระดับความพร้อมทางเทคโนโลยี (Technology Readiness Level: TRL) พบว่าไม่มีอุปกรณ์ใดที่อยู่ในระดับ TRL 8 ซึ่งสะท้อนถึงช่องว่างระหว่างการพัฒนาต้นแบบในห้องปฏิบัติการกับการนำไปใช้งานจริงในเชิงพาณิชย์ โดยเฉพาะในขั้นตอนการทดสอบในสภาพแวดล้อมจริงและการขอรับรองมาตรฐานก่อนการจำหน่าย

สำหรับมือเทียมในระดับแขนใต้ข้อศอก ซึ่งมีความใกล้เคียงกับขอบเขตของโครงงานนี้ พบว่ามีน้ำหนักอยู่ในช่วงประมาณ 100–980 กรัม และมีองศาอิสระ (Degrees of Freedom) อยู่ระหว่าง 0–20 องศา โดยมือเทียมเชิงพาณิชย์บางรุ่น เช่น Max Bionic สามารถรองรับรูปแบบการจับที่ตั้งโปรแกรมไว้ล่วงหน้าได้มากถึง 30 รูปแบบ

นอกจากนี้ งานวิจัยยังชี้ให้เห็นประเด็นด้านการเข้าถึง โดยระบุว่าผู้พิการแขนขาดประมาณ 4 ใน 5 ของโลกอาศัยอยู่ในประเทศกำลังพัฒนา ขณะที่มือเทียมเชิงพาณิชย์ระดับสูง เช่น LUKE Arm

สำหรับผู้พิการระดับแขนเหนือข้อศอกมีราคาสูงถึงประมาณ 100,000 ดอลลาร์สหรัฐ ซึ่งถือเป็นข้อจำกัดสำคัญในการเข้าถึงอุปกรณ์ของผู้ใช้งานส่วนใหญ่

งานวิจัยนี้มีความเกี่ยวข้องกับโครงงาน เนื่องจากช่วยกำหนดกรอบการออกแบบมือเทียมต้นแบบให้สอดคล้องกับแนวโน้มในปัจจุบัน โดยเฉพาะในระดับแขนใต้ข้อศอกทั้งในด้านน้ำหนัก องศาอิสระ และวิธีการควบคุมด้วยสัญญาณกล้ามเนื้อ อีกทั้งยังสนับสนุนแนวทางการพัฒนามือเทียมต้นทุนต่ำที่สามารถเข้าถึงได้ง่ายสำหรับผู้พิการในประเทศไทย

Guo, K. และคณะ (2567) ได้ทำการทบทวนวรรณกรรมอย่างเป็นระบบเกี่ยวกับความก้าวหน้าของมือเทียมเชิงชีวลักษณ์ โดยครอบคลุม 3 ด้านหลัก ได้แก่ กลไกการควบคุม การให้ข้อมูลป้อนกลับเชิงสัมผัส และการออกแบบเชิงกล โดยผู้วิจัยได้จำแนกโครงสร้างการขับเคลื่อนของมือเทียมออกเป็น 3 รูปแบบหลัก ได้แก่ การขับเคลื่อนด้วยเอ็น การขับเคลื่อนด้วยก้านโยง และการขับเคลื่อนด้วยมอเตอร์โดยตรง (Motor-Driven) ซึ่งพบว่าโครงสร้างแบบก้านโยงมีข้อได้เปรียบในด้านความแข็งแรง ความง่ายในการผลิตและการบำรุงรักษา รวมถึงสามารถให้แรงส่งออกได้สูง

ในด้านการควบคุม งานวิจัยนี้ยืนยันว่าการควบคุมด้วยสัญญาณกล้ามเนื้อ ยังเป็นวิธีที่มีความแม่นยำสูงและสามารถจำแนกท่าทางได้หลากหลายมากกว่าการควบคุมด้วยคลื่นสมอง และการเคลื่อนไหวลูกตา โดยได้รวบรวมผลการศึกษาเปรียบเทียบขั้นตอนวิธีการเรียนรู้ของเครื่อง สำหรับการจำแนกท่าทางมือจากสัญญาณกล้ามเนื้อ พบว่าโครงข่ายประสาทเทียม ที่พิจารณาความแตกต่างทางเพศของผู้ใช้ให้ความแม่นยำสูงสุดถึงร้อยละ 98.4 ขณะที่ตัวจำแนกประเภท K-Nearest Neighbor (KNN) และ เครื่องเวกเตอร์สนับสนุน ให้ความแม่นยำร้อยละ 94 และ 94.2 ตามลำดับ

นอกจากนี้ยังมีการศึกษาความสัมพันธ์ระหว่างจำนวนช่องสัญญาณกล้ามเนื้อกับความแม่นยำในการจำแนก โดยพบว่าการใช้ 7 ช่องสัญญาณให้ความแม่นยำเฉลี่ยร้อยละ 90.52 ซึ่งถือเป็นจุดสมดุลระหว่างความแม่นยำและภาระการประมวลผล สำหรับด้านลักษณะทางกายภาพของมือเทียม ผู้วิจัยรายงานว่าน้ำหนักมือมนุษย์โดยเฉลี่ยอยู่ที่ประมาณ 426 กรัม ขณะที่มือเทียมเชิงพาณิชย์ส่วนใหญ่อยู่ที่ประมาณ 500 กรัม โดยรุ่นที่เป็นที่รู้จัก เช่น i-Limb และ BeBionic Hand มีราคาประมาณ 18,000 และ 11,000 ดอลลาร์สหรัฐตามลำดับ

งานวิจัยยังชี้ให้เห็นปัญหาความไม่นิ่งของสัญญาณกล้ามเนื้อ ที่เกิดจากการเลื่อนตำแหน่งของอิเล็กโทรดและการเปลี่ยนแปลงของสภาพผิวหนัง ซึ่งยังคงเป็นข้อจำกัดสำคัญในการใช้งานจริงทั้งในสถานพยาบาลและในชีวิตประจำวัน ข้อมูลดังกล่าวเป็นประโยชน์ต่อโครงงานนี้ในการเลือกใช้ตัวจำแนกประเภทที่เหมาะสมสำหรับการประมวลผลสัญญาณกล้ามเนื้อด้วยไลบรารี scikit-learn รวมถึงการกำหนดเป้าหมายด้านน้ำหนักและแรงจับของมือเทียมต้นแบบให้ใกล้เคียงกับมือมนุษย์และมือเทียมเชิงพาณิชย์ในปัจจุบัน

บรรณานุกรม

[1] คมสันต์ เหล็มมะ และคณะ. (2561). การบาดเจ็บที่เกี่ยวเนื่องจากการทำงานและพฤติกรรมการทำงานที่ปลอดภัยของพนักงานโรงงานอุตสาหกรรมผลิตชิ้นส่วนรถยนต์. *พยาบาลสาร*, 45(4), 56-70.

[2] พุดตาน พันธุเณร และคณะ. (2561). การวิเคราะห์ความต้องการกำลังคนด้านสุขภาพสำหรับระบบบริการระดับทุติยภูมิของประเทศไทยในปี พ.ศ. 2569. *วารสารวิจัยระบบสาธารณสุข*, 12(2), 205-220.

[3] มณียฉัตร มาสมภพ. (2546). *ปัญหา ความต้องการ และระดับความพึงพอใจของผู้มารับบริการด้านกายอุปกรณ์.* สารนิพนธ์มหาบัณฑิต, มหาวิทยาลัยหัวเฉียวเฉลิมพระเกียรติ.

[4] Carey, S. L., et al. (2015). Differences in myoelectric and body-powered upper-limb prostheses: Systematic literature review. *JRRD*, 52(3), 247-262.

[5] Chadwell, A., et al. (2016). The Reality of Myoelectric Prostheses: Understanding What Makes These Devices Difficult for Some Users to Control. *Frontiers in Neurorobotics*, 10, 7.

[6] ten Kate, J., et al. (2017). 3D-printed upper limb prostheses: a review. *Disability and Rehabilitation: Assistive Technology*, 12(3), 300-314.

[7] Edwards, A. L., et al. (2016). Application of real-time machine learning to myoelectric prosthesis control: A case series in adaptive switching. *Prosthetics and Orthotics International*, 40(5), 573-581.

[8] Igual, C., et al. (2019). Myoelectric Control for Upper Limb Prostheses. *Electronics*, 8(11), 1244.

[9] Segura, D., et al. (2024). Upper Limb Prostheses by the Level of Amputation: A Systematic Review. *Prosthesis*, 6(2), 277-300.

[10] Guo, K., et al. (2024). The Latest Research Progress on Bionic Artificial Hands: A Systematic Review. *Micromachines*, 15(7), 891.